

PLAN

SOBOTA

Jakość i przygotowanie danych w projektach AI:
Znaczenie jakości danych: kompletność, spójność, aktualność. Metody oceny jakości danych (statystyki opisowe, walidacja reguł, wykrywanie anomalii).
Narzędzia do czyszczenia i transformacji danych (ETL).

Integracja danych z różnych źródeł: Data lakes, data warehouses, hurtownie danych. Migracja i łączenie danych z systemów wewnętrznych (CRM, ERP) i zewnętrznych (API, open data). Modelowanie danych i unifikacja schematów.

Proces przygotowania danych dla modeli AI: Wstępna analiza i eksploracja danych (EDA – Exploratory Data Analysis). Tworzenie i selekcja cech (feature engineering). Uzupełnianie braków danych, obsługa wartości odstających (outliers).

NIEDZIELA


Bezpieczeństwo danych – przepisy, regulacje i standardy branżowe: Normy i standardy (ISO 27001, ISO 27701) związane z bezpieczeństwem informacji. Dobre praktyki: polityki prywatności, systemy zarządzania danymi osobowymi.

Ochrona prywatności i etyka w zarządzaniu danymi: Anonimizacja, pseudonimizacja i tokenizacja danych. Świadoma zgoda na przetwarzanie danych, mechanizmy opt-out. Pułapki i ryzyka (np. bias w modelach związany ze stronniczością zbiorów danych).

Dane AI w praktyce

JAKOŚĆ PRZYGOTOWANIA DANYCH W PROJEKTACH AI

Znaczenie dokładnych i czystych danych dla sukcesu AI




ERA DANYCH W CODZIENNOŚCI



Wszechobecność danych

Dane otaczają nas wszędzie, od raportów biznesowych po statystyki z mediów społecznościowych.



Nowa umiejętność dla wszystkich

Analiza danych nie jest już domeną wyłącznie specjalistów. Każdy pracownik powinien znać podstawy pracy z informacją.




Wartość kompetencji danych

Umiejętność pracy z danymi jest coraz bardziej ceniona, niezależnie od stanowiska oraz branży.



OD DANYCH DO MĄDROŚCI



SKĄD POCHODZĄ DANE?

Różnorodność form danych

Dane występują pod postacią liczb, tekstów, obrazów, dźwięków i informacji lokalizacyjnych, umożliwiając szeroką analizę.

Znaczenie analizy danych

Analiza danych wspiera podejmowanie decyzji i pozwala lepiej zrozumieć działania firmy, klientów i rynku.

Uporządkowane i nieuporządkowane dane

Dane mogą być uporządkowane lub nieuporządkowane, co wpływa na metody ich analizy i wykorzystania.



TYPY DANYCH

Dane strukturalne

Dane strukturalne są uporządkowane w tabelach lub bazach danych, ułatwiając analizę i przetwarzanie, np. dane finansowe.

Dane niestrukuralne

Dane niestrukuralne obejmują e-maile, zdjęcia czy nagrania, które są trudne do klasyfikacji i analizy.

Dane półstrukturalne

Dane półstrukturalne, jak pliki XML i JSON, mają częściową strukturę, co ułatwia ich obróbkę w porównaniu z danymi niestrukuralnymi.

ŹRÓŁA DANYCH



Pliki

Bazy danych

Aplikacje biznesowe

Sensory, IoT

**GDZIE
PRZECHOWUJEMY
DANE?**

W BAZIE DANYCH

PRZECHOWYWANIE DANYCH W BAZIE



Bezpieczeństwo i dostępność danych

Baza danych zapewnia ochronę informacji oraz wygodny dostęp dla uprawnionych użytkowników w każdej chwili.



Szybkie wyszukiwanie i aktualizacja

Systemy bazodanowe umożliwiają sprawne wyszukiwanie oraz modyfikowanie danych, co usprawnia pracę.



Organizacja i ochrona informacji

Przechowywanie danych w bazie pozwala na ich uporządkowanie, zarządzanie oraz ochronę przed utratą.


CZYM JEST BAZA DANYCH?

Uporządkowany zbiór informacji

Baza danych przechowuje dane elektronicznie w zorganizowany i łatwy do zarządzania sposób, co umożliwia szybkie wyszukiwanie informacji.

Zarządzanie przez DBMS

System zarządzania bazą danych (DBMS) odpowiada za organizację, kontrolę dostępu i bezpieczeństwo przechowywanych danych.



ELEMENTY BAZY DANYCH

Schemat bazy danych

Schemat określa strukturę i powiązania danych w bazie, tworząc jej logiczny układ.

Dane

Dane to zapisane informacje, które stanowią główną zawartość każdej bazy danych.


Zapytania

Zapytania pozwalają na wyszukiwanie, modyfikowanie i analizowanie danych zapisanych w bazie.

Metadane

Metadane opisują strukturę i właściwości danych, ułatwiając zarządzanie informacjami.





ZNACZENIE TYPU BAZY DANYCH

Wpływ na wydajność aplikacji

Dobranie właściwego typu bazy danych znacząco poprawia wydajność i możliwości skalowania aplikacji biznesowych.

Charakterystyka baz relacyjnych


Relacyjne bazy danych zapewniają wysoką spójność transakcji i sprawdzają się w przypadku uporządkowanych danych.

Zastosowania baz NoSQL i wektorowych

NoSQL obsługuje duże, różnorodne dane, natomiast bazy wektorowe wspierają AI i wyszukiwanie semantyczne.

Konsekwencje złego wyboru

Nietrafiony wybór bazy danych może skutkować problemami w produkcji i ograniczeniami funkcjonalnymi aplikacji.



RELACYJNE BAZY DANYCH [SQL]

1. Relacyjne bazy danych wykorzystują model relacyjny, w którym dane są przechowywane w tabelach złożonych z wierszy i kolumn. Każda tabela odpowiada określonemu typowi encji, a powiązania między tabelami są określane za pomocą kluczy obcych.
2. Główne cechy relacyjnych baz danych to:
 1. Schemat - wymaga wcześniejszego zdefiniowania struktury przed wprowadzeniem danych;
 2. Użycie SQL (Structured Query Language) jako standardowego języka zapytań;
 3. Właściwości ACID gwarantujące spójność i bezpieczeństwo transakcji;
 - Atomicity (Niepodzielność) - transakcja jest wykonywana w całości lub wcale
 - Consistency (Spójność) - system zachowuje integralność danych
 - Isolation (Izolacja) - równoczesne transakcje nie wpływają na siebie
 - Durability (Trwałość) - zatwierdzone zmiany są trwale zapisane
 4. Normalizacja eliminuje redundancję danych i zapewnia ich uporządkowanie.

ZALETY I WADY RELACYJNYCH BAZ DANYCH




ZALETY

- Spójność i bezpieczeństwo transakcji (ACID) – gwarancja wiarygodności danych.
- Standaryzacja języka SQL – łatwa integracja i przenoszenie rozwiązań.
- Strukturalność – dane w tabelach z jasno zdefiniowanymi schematami.
- Eliminacja redundancji danych dzięki normalizacji.
- Obsługa złożonych zapytań, operacji JOIN i agregacji.

WADY

- Sztywność – konieczność wcześniejszego zdefiniowania struktury, utrudnia zmiany.
- Problemy ze skalowalnością przy dużych, nieustrukturyzowanych danych.
- Normalizacja może zwiększać liczbę tabel i złożoność zapytań.
- Wydajność spada w środowiskach rozproszonych i przy bardzo dużej liczbie transakcji.

NIERELACYJNE BAZY DANYCH (NOSQL)



1. Bazy NoSQL (Not Only SQL) to nierzeczywiste systemy baz danych, które nie wymagają sztywnego schematu i są zoptymalizowane pod kątem skalowalności oraz wydajności.
2. W przeciwieństwie do tradycyjnych baz relacyjnych, NoSQL pozwala na przechowywanie danych w elastycznych strukturach, co ułatwia obsługę dużych, różnorodnych i szybko zmieniających się zbiorów danych.
3. Często stosowane są w aplikacjach chmurowych, systemach analitycznych i rozwiązaniach AI, gdzie kluczowe są dostępność i możliwość skalowania poziomego (sharding)
4. Rodzaje baz NoSQL:
 1. Key-Value Stores – przechowują dane jako pary klucz-wartość; bardzo szybkie i proste w implementacji.
 2. Document Stores – dane w formacie dokumentów (np. JSON), umożliwiają zapytania na poziomie atrybutów dokumentu.
 3. Columnar / Wide-Column Stores – dane organizowane w kolumny i rodziny kolumn, dobre do analizy dużych zbiorów.
 4. Graph Databases – przechowują dane w postaci węzłów i krawędzi, idealne do analizy powiązań (np. sieci społecznościowe).

ZALETY I WADY BAZ NOSQL



ZALETY

- **Elastyczność** – brak sztywnego schematu, łatwe dostosowanie do zmieniających się danych.
- **Skalowalność pozioma** – możliwość dodawania nowych węzłów bez utraty wydajności.
- **Wysoka wydajność** – zoptymalizowane pod duże ilości danych i szybkie operacje.
- **Obsługa danych nieustrukturyzowanych** – idealne dla dokumentów, JSON, multimediów.
- **Dopasowanie do chmury i Big Data** – dobrze integrują się z rozproszonymi środowiskami.

WADY

- **Brak standaryzacji** – różne modele i języki zapytań w zależności od typu bazy.
- **Ograniczone wsparcie dla transakcji ACID** – trudniej zapewnić pełną spójność.
- **Mniejsza dojrzałość narzędzi** – w porównaniu z relacyjnymi bazami.
- **Złożoność przy analizach** – brak JOIN i skomplikowane zapytania w przypadku relacji.
- **Ryzyko vendor lock-in** – zależność od konkretnego dostawcy i jego API.

BAZY WEKTOROWE (VECTOR DATABASES)

Vector Database

Dimensions

Vectors

id									payload
id									payload
id									payload
id									payload
id									payload
id									payload
id									payload

1. Bazy wektorowe to specjalny typ baz danych zaprojektowany do przechowywania i wyszukiwania danych w postaci wektorów (embeddingów). Wektory reprezentują semantyczne znaczenie obiektów, takich jak tekst, obraz czy dźwięk, dzięki czemu możliwe jest wyszukiwanie podobieństwa na poziomie znaczeniowym, a nie tylko słów kluczowych. Są kluczowe w aplikacjach AI, szczególnie w systemach opartych na modelach językowych i wyszukiwaniu semantycznym.
2. Do czego służą?
 1. Wyszukiwanie semantyczne – odnajdywanie dokumentów, produktów czy treści podobnych znaczeniowo do zapytania, nawet jeśli nie zawierają tych samych słów.
 2. Rekomendacje – porównywanie podobieństwa między produktami, treściami czy użytkownikami.
 3. Integracja z LLM – umożliwiają implementację mechanizmów RAG (Retrieval-Augmented Generation), gdzie model pobiera kontekst z bazy wektorowej.
 4. Analiza dużych zbiorów danych – szybkie porównywanie i grupowanie obiektów na podstawie ich cech semantycznych.

ZALETY I WADY WEKTOROWYCH BAZ DANYCH



ZALETY

- **Wyszukiwanie semantyczne** – możliwość odnajdywania podobnych treści na podstawie znaczenia, a nie tylko słów kluczowych.
- **Integracja z LLM i RAG** – idealne do Retrieval-Augmented Generation, zapewniają kontekst dla modeli językowych.
- **Obsługa danych multimodalnych** – tekst, obrazy, dźwięk w jednym systemie.
- **Skalowalność** – zoptymalizowane pod duże zbiory danych i szybkie wyszukiwanie podobieństwa.
- **Wysoka trafność wyników** – algorytmy nearest neighbors zapewniają precyzyjne dopasowania.

WADY

- **Złożoność implementacji** – wymaga generowania embeddingów i integracji z modelami AI.
- **Koszty infrastruktury** – duże wymagania pamięciowe i obliczeniowe przy milionach wektorów.
- **Brak standaryzacji** – różne silniki (Milvus, Pinecone, Weaviate) mają odmienne API i funkcje.
- **Ograniczone wsparcie dla klasycznych operacji SQL** – brak JOIN, trudniejsze raportowanie.
- **Zależność od jakości embeddingów** – słabe modele = gorsze wyniki wyszukiwania.

KIEDY, GDZIE, KTÓRA?

Cecha	Relacyjne (SQL)	NoSQL	Wektorowe
Spójność danych	Wysoka (ACID)	Zależna od typu (BASE)	Niska – fokus na podobieństwo
Struktura	Sztywna, schematowa	Elastyczna	Embeddingi, wektory
Skalowalność	Pionowa	Pozioma	Pozioma
Typowe użycie	Transakcje, CRM	Logi, eventy, IoT	wyszukiwanie semantyczne

Relacyjne bazy danych (SQL)

Zastosowania: Automatyzacja procesów transakcyjnych – zarządzanie zamówieniami, faktury, systemy CRM.

Kluczowe cechy:

- Silna spójność danych (ACID).
- Doskonałe do złożonych relacji między encjami.
- Wysoka dojrzałość ekosystemu (SQL, narzędzia raportowe).

• **Przykłady:** Microsoft SQL Server, PostgreSQL, Oracle.

NoSQL

Zastosowania: Obsługa dużych wolumenów danych – przetwarzanie logów, agregacja metryk, obsługa eventów.

Kluczowe cechy:

- Elastyczny model danych (dokumenty, klucze-wartości, grafy).
- Skalowalność pozioma.
- Brak sztywnego schematu – idealne dla dynamicznych struktur.

• **Przykłady:** CosmosDB, MongoDB, Cassandra, Redis.

Bazy wektorowe

Zastosowania: Automatyzacja oparta na AI – przechowywanie embeddingów dokumentów firmowych, wsparcie chatbotów i wyszukiwania semantycznego.

Kluczowe cechy:

- Optymalizacja dla wyszukiwania podobieństwa (nearest neighbor search).
- Integracja z modelami ML/LLM.
- Umożliwia kontekstowe odpowiedzi na pytania w oparciu o wiedzę organizacyjną.

• **Przykłady:** Azure AI Search, Pinecone, Weaviate, Milvus.

CRISP-DM

Geneza i znaczenie CRISP-DM w eksploracji danych

Definicja CRISP-DM



Cross-Industry
Standard Process
for Data Mining

Otwarty, ustandaryzowany model procesu eksploracji danych

Opisuje typowe podejścia stosowane przez praktyków data mining



Geneza CRISP-DM

Opracowany w latach 1996–1999 w ramach projektu finansowanego przez ESPRIT

Uczestnicy: Integral Solutions (później SPSS), Teradata, Daimler-Benz, NCR, ubezpieczyciel OHA
Branżowa niezależność i neutralność narzędziowa

Znaczenie i popularność


„De facto” standard w projektach eksploracji danych od końca lat 90.
W 2007 r. około 43% analityków korzystało CRISP-DM

(źródło: KDnuggets)

Zapewnia uporządkowaną strukturę



SZEŚĆ FAZ CRISP-DM



ZROZUMIENIE BIZNESU (BUSINESS UNDERSTANDING)

Dokładne określenia zakresu i wymagań projektu z perspektywy biznesowej

- **Określenie celów biznesowych** – przeprowadzenie rozmów z interesariuszami w celu ustalenia, „czego tak naprawdę klient chce” i zdefiniowania kryteriów biznesowego sukcesu.
- **Ocena sytuacji** – analiza dostępnych zasobów, ograniczeń, ryzyka oraz opłacalności projektu.
- **Wyznaczenie celów eksploracyjnych** – przekształcenie celów biznesowych w mierzalne cele związane z analizą danych i określenie wymagań dotyczących modeli analitycznych.
- **Przygotowanie planu projektu** – wybór narzędzi, podział zadań i harmonogram prac.

ZROZUMIENIE DANYCH (DATA UNDERSTANDING)

Identyfikacja i gromadzenie odpowiednich danych, badanie ich charakterystyki oraz ocena jakości

- **Zebrać początkowe dane** – pozyskać dane z różnorodnych źródeł i załadować je do narzędzi analitycznych
- **Opisać dane** – udokumentować podstawowe cechy, takie jak format pola, liczba rekordów i znaczenie atrybutów
- **Eksplorować dane** – analizować ich rozkłady, korelacje, wykrywać wzorce, outlier'y i potencjalne nieliniowości za pomocą statystyki opisowej oraz wizualizacji
- **Sprawdzić jakość danych** – ocenić kompletność i zgodność danych, wskazać problemy z czyszczeniem lub brakami

PRZYGOTOWANIE DANYCH (DATA PREPARATION)

Powstaje ostateczny zbiór danych do modelowania

- **Wybór danych** – selekcja odpowiednich zmiennych i zbiorów, uzasadnienie decyzji o ich wykorzystaniu lub odrzuceniu
- **Czyszczenie danych** – usuwanie lub imputowanie wartości błędnych, obsługa braków oraz outlier'ów
- **Konstrukcja cech** – tworzenie nowych zmiennych pochodnych, przydatnych w modelowaniu (np. wskaźniki, transformacje)
- **Integracja danych** – łączenie danych z różnych źródeł w spójny zbiór
- **Formatowanie danych** – konwersja typów, standaryzacja jednostek i formatu danych w celu ułatwienia analizy

MODELOWANIE

Wybór algorytmów, budowa modeli do prognozowania, klasyfikacji lub opis zjawisk

- **Dobór technik modelowania** – wybór algorytmów adekwatnych do problemu (regresja, drzewa decyzyjne, klasteryzacja, sieci neuronowe) z uwzględnieniem interpretowalności, złożoności i zasobów obliczeniowych
- **Opracowanie schematu testowego** – podział danych na zbiory treningowe, testowe (i ewentualnie walidacyjne) oraz wybór metryk oceny (np. dokładność, czułość)
- **Budowa modeli** – implementacja algorytmów i trenowanie modeli z wykorzystaniem przygotowanych danych
- **Ocena modeli** – interpretacja wyników, porównywanie różnych modeli i wybór najlepszego rozwiązania zgodnie z kryteriami sukcesu zdefiniowanymi na etapie zrozumienia biznesu

EWALUACJA (EVALUATION)

Czy wyniki odpowiadają na pytania biznesowe i spełniają kryteria sukcesu


- **Ocenić wyniki** – sprawdzić, czy model (lub wynik analizy statystycznej) spełnia cele biznesowe i techniczne
- **Przeglądnąć cały proces** – upewnić się, że żadne kroki nie zostały pominięte, uporządkować wnioski i w razie potrzeby powrócić do wcześniejszych etapów
- **Określić kolejne kroki** – zdecydować, czy przejść do wdrożenia, kontynuować iteracje, czy zmodyfikować zakres projektu

WDROŻENIE (DEPLOYMENT)

Przeniesieniu wyników analizy do środowiska operacyjnego

- **Plan wdrożenia** – określenie sposobu, w jaki model zostanie osadzony w systemach i kto będzie za to odpowiedzialny
- **Plan monitorowania i utrzymania** – ustalenie procedur kontroli jakości modelu i jego aktualizacji w miarę zmiany danych lub wymagań
- **Raport końcowy** – podsumowanie projektu i zaprezentowanie rezultatów interesariuszom
- **Retrospekcja projektu** – analiza doświadczeń i identyfikacja obszarów do udoskonalenia w przyszłych przedsięwzięciach

SZEŚĆ FAZ CRISP-DM



ITERACYJNOŚĆ I ADAPTACYJNOŚĆ CRISP-DM

Cykliczny charakter procesu


CRISP-DM umożliwia wielokrotny powrót do poprzednich etapów, co pozwala na bieżąco rozwiązywać nowe problemy i ulepszać projekt.

Elastyczność przechodzenia między fazami

Swobodne przechodzenie między etapami w zależności od wyników zwiększa elastyczność i skuteczność analizy danych.

Integracja ze zwinnością biznesową

Model dobrze współgra z praktykami zwinnego zarządzania, umożliwiając szybkie reagowanie na zmiany i tworzenie adaptacyjnych rozwiązań.



ZASTOSOWANIA CRISP-DM W PRAKTYCE

Analiza w handlu detalicznym

CRISP-DM umożliwia analizę zachowań klientów i personalizację ofert, zwiększając skuteczność sprzedaży i zadowolenie klientów.

Zastosowania w finansach

Instytucje finansowe stosują CRISP-DM do oceny ryzyka kredytowego i wykrywania oszustw, poprawiając bezpieczeństwo i zarządzanie ryzykiem.

Optymalizacja w medycynie

CRISP-DM pomaga przewidywać przebieg chorób oraz optymalizować opiekę zdrowotną, wspierając lepsze decyzje medyczne.



ZALETY METODYKI CRISP-DM

Uporządkowana i przejrzysta struktura

Sześć etapów CRISP-DM wspiera planowanie, nadzór projektu i jasną komunikację w całym zespole.

Uniwersalność i elastyczność

Metodyka łatwo dopasowuje się do różnych branż, narzędzi oraz może być łączona z podejściem Agile.

Nastawienie na cele biznesowe

Priorytetem jest analiza danych powiązana z rzeczywistymi problemami biznesowymi i szybkie dostarczanie rezultatów.

Optymalizacja zasobów i minimalizacja ryzyka

Metodyka pozwala lepiej wykorzystywać dostępne zasoby i zmniejsza ryzyko niepowodzenia projektu.



WYZWANIA I REKOMENDACJE CRISP-DM

Jakość i integracja danych

Niska jakość lub brak integracji danych prowadzi do błędnych wniosków. Kontrola jakości i ujednolicenie są kluczowe.

Elastyczność wobec zmian biznesowych

Zmienne cele biznesowe wymagają powrotów do wcześniejszych etapów procesu i dostosowania analizy.

Zwinność i iteracje

Łączenie schematu CRISP-DM z podejściem zwinnym i iteracjami daje lepsze efekty i szybciej reaguje na potrzeby.

Monitoring i aktualizacja modeli

Po wdrożeniu należy monitorować i regularnie aktualizować modele, angażując użytkowników końcowych.



CRISP-DM — KLUCZOWE WNIOSKI

Struktura i elastyczność procesu

CRISP-DM zapewnia uporządkowaną strukturę realizacji projektów analitycznych, jednocześnie umożliwiając elastyczne przechodzenie między fazami procesu.

Realizacja celów biznesowych

Metodyka koncentruje się na osiągnięciu konkretnych celów biznesowych, a nie tylko na analizie danych.

Fundament dla data-science

Znajomość CRISP-DM jest kluczowa dla studentów i praktyków, umożliwia świadome budowanie modeli odpowiadających rzeczywistym potrzebom.



ZARZADZANIE DANYMI

ONE DASHBOARD TO RULE THEM ALL



OBSZARY ZARZĄDZANIA DANYCH

Pobieranie

Przygotowanie

Przechowywanie

Analiza

PROCESY ETL I ELT

Proces ETL



ETL polega na wydobywaniu danych, ich transformacji i ładowaniu do wybranego systemu docelowego. Jest powszechnie stosowany w tradycyjnych hurtowniach danych.

Proces ELT

ELT najpierw ładuje dane do systemu docelowego, a następnie wykonuje transformacje już na miejscu, często w środowiskach chmurowych.

Zastosowanie technologii

ETL dominuje w tradycyjnych hurtowniach danych, natomiast ELT jest popularny w nowoczesnych rozwiązaniach chmurowych i dużych zbiorach danych.



PROCES ETL

Extract (Wyodrębnianie danych)

Pierwszy etap polega na pobraniu danych z różnych źródeł, np.:

- Relacyjne bazy danych (SQL Server, PostgreSQL)
- Pliki CSV, Excel, logi systemowe
- API aplikacji (CRM, ERP)
- Dane z systemów IoT lub strumieniowych

Przykład:

- Za pomocą **Azure Data Factory** stworzysz pipeline, który pobiera dane sprzedażowe z systemu ERP oraz pliki CSV z magazynu Blob Storage.

Transform (Transformacja danych)

To kluczowy etap, w którym dane są czyszczone, standaryzowane i wzbogacane:

- **Czyszczenie:** usuwanie duplikatów, uzupełnianie braków, poprawa błędów
- **Standaryzacja:** konwersja dat do jednego formatu, normalizacja jednostek
- **Agregacja i mapowanie:** łączenie danych z różnych tabel, tworzenie sum, średnich
- **Enrichment:** dodanie dodatkowych informacji, np. geolokalizacji
- **Zmiana struktury:** pivotowanie tabel, tworzenie hierarchii

Load (Ładowanie danych)

Ostatni etap polega na załadowaniu przetworzonych danych do systemu docelowego:

- Hurtownia danych (np. **Microsoft Fabric**)
- Data Lake (np. **Azure Data Lake Storage**)
- Narzędzia BI (np. Power BI)

PROCES ELT

Extract (Wyodrębnianie danych)

Pierwszy etap polega na pobraniu danych z różnych źródeł, np.:

- Relacyjne bazy danych (SQL Server, PostgreSQL)
- Pliki CSV, Excel, logi systemowe
- API aplikacji (CRM, ERP)
- Dane z systemów IoT lub strumieniowych

Przykład:

- Za pomocą **Azure Data Factory** tworzysz pipeline, który pobiera dane sprzedażowe z systemu ERP oraz pliki CSV z magazynu Blob Storage.

Load (Ładowanie danych)

Drugi etap polega na załadowaniu danych do systemu docelowego:

- OneLake

Transform (Transformacja danych)

Ostatni etap, w którym dane są czyszczone, standaryzowane i wzbogacane:

- **Czyszczenie:** usuwanie duplikatów, uzupełnianie braków, poprawa błędów
- **Standaryzacja:** konwersja dat do jednego formatu, normalizacja jednostek
- **Agregacja i mapowanie:** łączenie danych z różnych tabel, tworzenie sum, średnich
- **Enrichment:** dodanie dodatkowych informacji, np. geolokalizacji
- **Zmiana struktury:** pivotowanie tabel, tworzenie hierarchii

PORÓWNIANIE ETL VS ELT

Cecha	ETL (Extract, Transform, Load)	ELT (Extract, Load, Transform)
Kolejność etapów	Dane są przekształcane przed załadowaniem	Dane są przekształcane po załadowaniu
Miejsce transformacji	W narzędziu ETL lub serwerze pośrednim	W rozwiązaniu danych (np. Microsoft Fabric, Snowflake)
Wydajność	Ograniczona mocą serwera ETL	Wykorzystuje moc obliczeniową rozwiązania (skalowalność)
Złożoność	Większa konfiguracja narzędzi ETL	Prostsza logikę można realizować w SQL w rozwiązaniu
Koszt	Może wymagać dodatkowej infrastruktury ETL	Zależny od kosztów hurtowni i jej zasobów
Przykłady narzędzi	Azure Data Factory, Informatica, Talend	Microsoft Fabric, BigQuery, Snowflake
Zastosowanie	Gdy dane wymagają intensywnej transformacji przed load	Gdy hurtownia jest wydajna i może obsłużyć transformacje

EXTRACT

EXTRACT, POBIERANIE (INGESTION)

- Ingestion to etap wprowadzania danych do środowiska chmurowego, np. Azure Data Lake, Synapse czy Data Explorer.
- **Źródła danych:** systemy on-premises, IoT, aplikacje SaaS, pliki (CSV, JSON, Parquet).
- **Metody pobierania:**
 - **Batch ingestion** – ładowanie dużych wolumenów danych w partiach (np. dane historyczne).
 - **Streaming ingestion** – przesyłanie danych w czasie rzeczywistym (np. telemetryka, logi).
- **Transformacja i walidacja:** dopasowanie schematów, czyszczenie danych, kompresja, indeksowanie.
- **Ładowanie do docelowych usług:** Azure Data Lake, Azure SQL, Synapse Analytics, Cosmos DB.

WYZWANIA POBIERANIA DANYCH

- **Wolnozmiennie dane (Slowly Changing Dimensions – SCD):**
 - Problem: zachowanie historii zmian (np. zmiana adresu klienta).
 - Wyzwania: wersjonowanie rekordów, obsługa metadanych, integracja z hurtownią danych.
 - Typowe podejścia: SCD Type 1 (nadpisanie), Type 2 (dodanie nowego wiersza), Type 3 (kolumna dla poprzedniej wartości).
- **Szybkozmiennie dane (Fast-changing):**
 - Wyzwania: skalowalność, niska latencja, obsługa dużych wolumenów w czasie rzeczywistym.
 - Ryzyko: utrata danych przy awarii, konieczność mechanizmów retry i „at least once delivery”.
 - Optymalizacja: mikro-batche, kolejki (Event Hub, Kafka), mechanizmy CDC (Change Data Capture).

NAJWAŻNIEJSZE FORMATY PLIKÓW

CSV

JSON

YAML

TOON

Parquet

CSV

- **Charakterystyka:** prosty, tabelaryczny, bez wbudowanego schematu.
- **Zalety:** powszechny, niewielki narzut, łatwy do otwarcia w Excelu/BI.
- **Wady:** brak typów i schematu, problemy z separatorami/encodingiem, słabe zagnieżdżenia.
- **Przykład**

```
id;name;price;created_at  
101;„Klawiatura Pro”;129.99;2025-12-01  
102;„Mysz Bezpr
```


JSON

- **Charakterystyka:** obiektowy, dobry dla zagnieżdżonych struktur (API, logi).
- **Zalety:** elastyczny, szerokie wsparcie w narzędziach.
- **Wady:** bardziej „gadatliwy” (większe zużycie tokenów niż TOON), brak sztywnego schematu bez JSON Schema.
- **Przykład**

```
{  
  "orderId": 12345,  
  "customer": { "name": "Jan Kowalski", "email": "jan@example.com" },  
  "items": [  
    { "sku": "SKU-001", "qty": 2, "price": 19.99 },  
    { "sku": "SKU-002", "qty": 1, "price": 49.90 }  
  ],  
  "createdAt": "2025-12-07T10:15:00Z",  
  "paid": true  
}
```

YAML

- **Charakterystyka:** tekstowy, czytelny dla ludzi, oparty na wcięciach (konfiguracje, CI/CD).
- **Zalety:** przejrzystość, komentarze, aliasy.
- **Wady:** wrażliwy na wcięcia, brak ścisłej walidacji bez dodatkowych narzędzi.
- **Przykład**

```
app:
  name: raporty-sprzedazy
  enabled: true
  retries: 3
  sources:
    - type: csv
      path: "abfss://bronze@lake.dfs.core.windows.net/sales/*.csv"
    - type: json
      path: "abfss://bronze@lake.dfs.core.windows.net/events/*.json"
```

TOON

- **Charakterystyka:** kompaktowy, czytelny format zaprojektowany tak, aby minimalizować zużycie tokenów przy wymianie strukturalnych danych z modelami LLM — łączy czytelność YAML z tabelaryczną efektywnością CSV.
- **Zalety:** istotnie niższa „gadatliwość” niż JSON; sprzyja częstym interakcjom z LLM; zachowuje czytelność.
- **Wady:** nowy format — ograniczona standaryzacja i tooling; konieczność jasnych zasad eskapowania i definicji schematu; potencjalna potrzeba konwersji do JSON/Parquet w pipeline’ach.

```
users[3]{id,name,email,role,active}:  
  1,Ada Lovelace,ada@example.com,admin,true  
  2,Jan Kowalski,jan@example.com,user,false  
  3,Anna Nowak,anna@example.com,moderator,true  
  
tags[3]: ai,data,llm
```

PARQUET

- **Charakterystyka:** binarny, **kolumnowy** format z kompresją i wbudowanym schematem (big data, lakehouse).
- **Zalety:** wysoka kompresja, szybkie skany kolumnowe, świetny do analityki i ML.
- **Wady:** nieczytelny dla człowieka; mniej wygodny do ad-hoc edycji.

PORÓWNIANIE

Format	Czytelność	Zagnieżdżenia	Schemat	Wydajność	Kompresja	Typowe użycie
CSV	wysoka	słabe	brak	niska	brak	eksport/ import
JSON	średnia	bardzo dobre	opcjonalny	średnia	średnia	API, logi
YAML	wysoka	dobre	brak	niska	średnia	konfiguracje
TOON	wysoka	dobre	wymaga definicji	średnia	średnia	LLM interakcje
Parquet	niska	średnie	wbudowany	wysoka	wysoka	analitika big data

ROZWIĄZANIA W AZURE

Orkiestracja

- **Azure Data Factory (ADF):**
 - Graficzne projektowanie potoków danych (no-code/low-code).
 - 90+ konektorów do źródeł danych.
 - Obsługa batch i integracji hybrydowej (on-prem + cloud).
- **Azure Synapse Analytics:**
 - Integracja hurtowni danych z big data.
 - Transformacje T-SQL lub Spark.a
- **Azure Databricks:**
 - Zaawansowane przetwarzanie big data i ML.
 - Obsługa PySpark, Scala, SQL.

Streaming i szybkozmienne dane

- **Azure Event Hubs / IoT Hub** – strumieniowanie danych telemetrycznych.
- **Azure Stream Analytics** – analiza danych w czasie rzeczywistym.
- **Azure Data Explorer (ADX):**
 - Obsługa ingestion z wielu źródeł (Event Hub, IoT Hub, Blob).
 - Format: CSV, JSON, Avro, kompresja ZIP/GZIP.
 - Tryby: streaming ingestion (niska latencja) i queued ingestion (wysoka przepustowość).

Dodatkowe narzędzia

- **Azure Purview** – zarządzanie metadanymi i zgodnością.
- **Power Automate** – automatyzacja prostych przepływów danych.
- **Medallion Architecture (Bronze/Silver/Gold)** – warstwowe podejście do organizacji danych w OneLake


TRANSFORM

TRANSFORMACJA DANYCH

- Transformacja danych to kluczowy etap, który polega na przekształceniu danych z ich źródłowego formatu do formatu docelowego, zgodnego z wymaganiami systemu analitycznego, hurtowni danych lub aplikacji.
- Transformacja danych to proces modyfikowania, czyszczenia i wzbogacania danych po ich pobraniu (Extract) z różnych źródeł. Może obejmować:
 - Czyszczenie danych – usuwanie duplikatów, uzupełnianie braków, poprawa błędów.
 - Standaryzacja – np. konwersja dat do jednego formatu, normalizacja jednostek.
 - Mapowanie i agregacja – łączenie danych z różnych tabel, tworzenie sum, średnich.
 - Enrichment (wzbogacanie) – dodawanie dodatkowych informacji, np. geolokalizacji.
 - Zmiana struktury – np. pivotowanie tabel, tworzenie hierarchii.
- Transformacja danych jest niezbędna, aby:
 - Zapewnić spójność i jakość danych – dane z różnych źródeł muszą być jednolite.
 - Dostosować dane do modelu analitycznego – np. do schematu hurtowni danych.
 - Przygotować dane do raportowania i analizy – np. w Power BI, Azure Synapse.
 - Spełnić wymagania biznesowe i compliance – np. anonimizacja danych wrażliwych.

LOAD

DANE W MICROSOFT FABRIC



CO TO JEST MIRRORING?

Definicja mirroringu

Mirroring to technologia utrzymująca (dwie?) kopie bazy danych na oddzielnych serwerach dla wysokiej dostępności.

Tryby działania


Mirroring działa w trybie wysokiej dostępności z pełną synchronizacją lub wysokiej wydajności z asynchroniczną synchronizacją.

Zalety i ograniczenia

Zapewnia ciągłość działania przy awarii, ale ogranicza skalowalność przez brak równoległego odczytu z kopii zapasowej.

Zastosowania i konfiguracja

Mirroring jest konfigurowany na poziomie bazy danych i często łączony z innymi mechanizmami zabezpieczeń.



CO TO JEST REPLIKACJA?

Definicja replikacji SQL Server

Replikacja to kopiowanie i dystrybucja danych między serwerami dla zwiększenia dostępności i skalowalności.

Typy replikacji


Replikacja obejmuje snapshot, transactional i merge, różniące się sposobem synchronizacji danych.

Zastosowania i korzyści

Replikacja umożliwia lokalny dostęp do danych i rozproszenie obciążeń, zwiększając elastyczność systemów.

Wyzwania konfiguracji

Konfiguracja jest złożona, a problemy z integralnością danych mogą wystąpić przy awariach sieci.




MIRRORING VS REPLIKACJA

Parametr	Mirroring	Replikacja
Podstawy	Mirroring to kopiowanie danych lub bazy danych do innej lokalizacji.	Replikacja to tworzenie danych i obiektów bazy w celu zwiększenia dystrybucji.
Wykonywane na	Mirroring wykonujemy na całej bazie danych.	Replikację wykonujemy na obiektach danych i bazy danych.
Koszt	Operacja mirroringu na bazie danych jest droższa niż replikacja.	Replikacja jest tańsza niż mirroring.
Rozproszona baza	Mirroring nie obsługuje rozproszonych baz danych.	Replikacja obsługuje rozproszone bazy danych.
Lokalizacja	Zwykle baza lustrzana jest wdrażana na innym serwerze lub w innej lokalizacji niż baza główna.	W replikacji baza i obiekty danych są przechowywane w innej bazie danych.

MIRRORING VS REPLIKACJA

Cecha	Mirroring	Replikacja
Dostępność	Wysoka	Średnia
Skalowalność	Niska	Wysoka
Koszt	Wysoki	Średni
Zastosowanie	Failover	Dystrybucja danych

TOOLS



AZURE DATA FACTORY, INFORMATICA, TALEND, APACHE NIFI

Azure Data Factory

Chmurowe narzędzie do orkiestracji potoków danych i integracji hybrydowej z zaawansowaną analityką.

Informatica

Enterprise klasy narzędzie oferujące integrację danych, transformację oraz zarządzanie jakością danych.

Talend

Popularne open-source rozwiązanie zapewniające elastyczność i bogaty zestaw komponentów do integracji.

Apache NiFi

Narzędzie do przetwarzania strumieniowego danych, idealne dla IoT i przetwarzania w czasie rzeczywistym.

PORÓWNIANIE FUNKCJI I MOŻLIWOŚCI

NARZĘDZIE	UI	INTEGRACJA	STREAMING	ANALITYKA
Azure Data Factory	Intuicyjne	Integracja z Azure	Brak natywnego streamingu	Synapse Analytics
Informatica	Zaawansowane	Enterprise	Ograniczone	Rozbudowane raporty
Talend	Przyjazne	Open-source	Ograniczone	Podstawowe
Apache NiFi	Proste	Integracja IoT	Pełne wsparcie	Brak analizy batch

INTEGRACJA DANYCH Z RÓŻNYCH ŹRÓDEŁ





DROGA DO SPÓJNEJ ANALITYKI

Wyzwania silosów informacyjnych

Silosy informacyjne powodują fragmentację danych przez różnorodność formatów oraz schematów, co utrudnia analizę i podejmowanie decyzji.

Zintegrowane podejście do danych

Łączenie danych z CRM, ERP, chmury i źródeł publicznych umożliwia pełniejszą oraz trafniejszą analizę biznesową.

Ujednolicenie semantyki danych

Kluczowe jest scalenie i standaryzacja semantyki danych, aby cała organizacja miała spójne i porównywalne informacje.

WIELOŚĆ ŹRÓDEŁ I FORMATÓW

Wiele systemów źródłowych

Organizacje korzystają z licznych systemów IT; kluczowe informacje powstają w środowiskach wewnętrznych, takich jak CRM i ERP.

Rosnąca rola danych zewnętrznych

Wartościowe źródła to także interfejsy API, rejestry publiczne i „open data” (np. dane meteorologiczne, statystyki urzędowe).

Integracja i wspólna semantyka

Różnorodność formatów i skala danych tworzą silosy i utrudniają spójne analizy. Eksperci Esri podkreślają potrzebę ich rozbijania i łączenia zbiorów dla pełnego obrazu.





ARCHITEKTURY DANYCH: JEZIORA I HURTOWNIE



HURTOWNIE DANYCH (Data Warehouse)

Definicja i przeznaczenie

Hurtownia danych to wyspecjalizowane repozytorium uporządkowanych danych, zaprojektowane do szybkich analiz i raportowania w środowisku business intelligence.

Schema-on-write

Dane są transformowane i strukturyzowane podczas ładowania, co zwiększa wydajność zapytań oraz jakość analiz dla danych o ustalonym schemacie (np. transakcje, zapisy księgowe).

Optymalizacja i zgodność

Wstępna strukturyzacja ułatwia szybkie tworzenie raportów i dashboardów, zapewnia integralność danych oraz zgodność ze standardami i regulacjami.

JEZIORO DANYCH

Data Lake

Definicja i przeznaczenie

Jezioro danych to scentralizowane repozytorium surowych, nie- i pół-ustrukturyzowanych danych. Są określane jako 'zbiorniki surowych danych' pozwalające gromadzić informacje bez natychmiastowych ograniczeń struktury.

Schema-on-read i elastyczność

Schemat danych tworzony jest przy odczycie, co zwiększa elastyczność analizy i szybkość pozyskiwania. Umożliwia przechowywanie tekstu, multimediów i danych sensorycznych z pełnym poziomem szczegółowości.

Wyzwania analityczne i wydajność

Cena tej swobody to potrzeba zaawansowanych narzędzi zapytań oraz potencjalnie niższa wydajność analiz surowych danych, szczególnie przy dużej skali i różnorodności formatów.



JEZIORO VS HURTOWNIA => LAKEHOUSE

Różnice między jeziorem a hurtownią

Jeziora danych przechowują surowe, niestrukturalne i pół-ustrukturalne dane z podejściem schema-on-read; hurtownie koncentrują się na danych strukturalnych i schema-on-write, zapewniając wysoką jakość i wydajność zapytań. Jeziora są tańsze dzięki magazynom obiektowym; hurtownie generują wyższe koszty obliczeniowe.

Integracja: ETL vs ELT

Model hybrydowy kieruje surowe dane do jeziora, gdzie są walidowane i transformowane wsadowo lub strumieniowo. ETL transformuje przed załadunkiem; ELT wykonuje transformacje na hurtowni, wspierając precyzyjne analizy biznesowe.


„Lakehouse”: synergia i zastosowania

Koncepcja lakehouse łączy elastyczność jeziora i wydajność zapytań hurtowni, wspierając eksplorację, analitykę big data, uczenie maszynowe oraz raportowanie i analizy BI. Wybór zależy od charakteru danych i celów biznesowych.




ENTERPRISE DATA ANALYTICS EVOLUTION TIMELINE

Late 1980s – Mid 2000s



Mid 2000s – 2020




2021 - Present

LAKEHOUSE – Powered by Delta Lake, Iceberg, and Hudi



ENTERPRISE DATA ANALYTICS – HURTOWNIA DANYCH

Koniec lat 80. – połowa lat 2000



Przypadki użycia


- Agregowane dane z baz danych OLTP i innych źródeł
- Jedno źródło prawdy
- Zastosowania Business Intelligence
- Wysokie wymagania współbiegu / niskie opóźnienia
- Wspiera transakcje ACID
- Optymalizuj zapytania (indeksy, widoki itp.)
- Zarządzanie i audyt

Ograniczenia

- Ograniczone wsparcie dla przypadków użycia ML/AI
- Ograniczone wsparcie dla zastosowań streamingu
- Ograniczone wsparcie dla typów/formatów danych
- Drogie przechowywanie danych w skali petabajtów
- Obliczenia nieelastyczne (rozwiązane za pomocą DW opartego na chmurze)
- Vendor lock-in

ENTERPRISE DATA ANALYTICS – DATA LAKE

Mid 2000s – 2020



Przypadki użycia

- Przypadki użycia ML/AI
- Zastosowanie do Streamingu
- Obsługa wszystkich typów danych
- Tanie przechowywanie danych w skali petabajtów
- Obliczenia rozproszone i odporność na błędy
- Odłączenie obliczeń od pamięci

Ograniczenia


- Ograniczone wsparcie dla transakcji ACID
- Wolny czas odpowiedzi na zapytania
- Problemy z jakością danych
- Za dużo plików
- Problemy z przetwarzaniem dużych metadanych
- Nieelastyczne (rozwiązane przez magazyny obiektów w chmurze)
- Skomplikowane do zarządzania i monitorowania

DATA LAKEHOUSE ARCHITECTURE


Data Warehouse



Data Lake



Data Lakehouse



Paradigm Shift: Lakehouse



Data
Lake




Lakehouse

One platform to unify all of your
data, analytics, and AI workloads



Data
Warehouse

Azure Lakehouse Architecture – Synapse & Databricks




ARCHITEKTURA MEDALIONU

- **Architektura medalionu** opisuje serię warstw danych, które określają jakość danych przechowywanych w Lakehouse. Usługa Azure Databricks zaleca zastosowanie wielowarstwowego podejścia do stworzenia jednego źródła prawdy dla produktów danych korporacyjnych.
- Ta architektura gwarantuje niepodzielność, spójność, izolację i trwałość, ponieważ dane przechodzą przez wiele warstw weryfikacji i przekształceń przed zapisaniem w układzie zoptymalizowanym pod kątem wydajnej analizy. Terminy **brązowe** (surowe), **srebrne** (zweryfikowane) i **złote** (wzbogacone) opisują jakość danych w każdej z tych warstw.

ARCHITEKTURY MEDALONU

Pytanie	Brąz	Srebrny	Złoty
Co się dzieje w tej warstwie?	Pozyskiwanie nieprzetworzonych danych	Czyszczenie i walidacja danych	Modelowanie wymiarowe i agregacja
Kto jest użytkownikiem?	• Inżynierowie danych • Operacje na danych • Zespoły ds. zgodności i inspekcji	• Inżynierowie danych • Analitycy danych (używają warstwy Silver do bardziej wyrafinowanego zestawu danych, który nadal przechowuje szczegółowe informacje niezbędne do szczegółowej analizy) • Analitycy danych (tworzenie modeli i wykonywanie zaawansowanych analiz)	• Analitycy biznesowi i deweloperzy analizy biznesowej • Analitycy danych i inżynierowie uczenia maszynowego • Kierownictwo i osoby podejmujące decyzje • Zespoły operacyjne

PRZYKŁADOWA ARCHITEKTURA MEDALIONU



PRZYKŁAD RZECZYWISTY

- Rozważmy następujący przykład firmy zajmującej się handlem elektronicznym, która stosuje architekturę medalonu do swoich danych:
- **Warstwa brązowa:**
 - Przechowywanie nieprzetworzonych danych sprzedaży z witryny internetowej (JSON)
 - Przechowuj surowe dane inwentarzowe z magazynu (CSV)
 - Przechowywanie nieprzetworzonych danych klientów z programu CRM (eksport SQL)
- **Warstwa srebra:**
 - Standaryzacja formatów dat we wszystkich źródłach
 - Przekonwertuj całą walutę na USD
 - Usuwanie transakcji testowych
 - Dopasowywanie rekordów klientów między systemami
- **Warstwa złota:**
 - Utwórz dzienną tabelę dashboardu sprzedaży
 - Tworzenie tabeli wartości okresu istnienia klienta
 - Generowanie tabeli prognozowania spisu

MODEL WDRAŻANIA




Wzorzec 1: Utwórz każdą warstwę jako jezioro. W takim przypadku użytkownicy biznesowi uzyskują dostęp do danych przy użyciu punktu końcowego analizy SQL.




Wzorzec 2: Utwórz warstwy brązową i srebrną jako lakehouse'y, a warstwę złotą jako magazyn danych. W takim przypadku użytkownicy biznesowi uzyskują dostęp do danych przy użyciu punktu końcowego magazynu danych.

LOAD - POWER BI



DATA E2E

Data Source



Structured /
Unstructured



Ingestion



Pipeline

Transform




Dataflows Gen2

Store



Lakehouse

Expose



Business Intelligence

Orchestration & Notification



Pipeline



INTEGRACJA DANYCH: CRM, ERP, API

INTEGRACJA DANYCH W LAKEHOUSE

Źródła danych

CRM i ERP, usługi chmurowe, API, czujniki IoT oraz systemy transakcyjne. Integracja eliminuje silosy i ułatwia pełny obraz biznesu.

Metody integracji

Batch i streaming; ETL vs ELT; CDC, kolejki komunikatów, wirtualizacja i zapytania federowane dla różnych potrzeb i SLAs.

Bezpieczeństwo i jakość

Kontrola dostępu, zgodność, obserwowalność oraz walidacja i wersjonowanie w formatach ACID (Delta, Iceberg) dla skalowalności.



TRYBY INTEGRACJI: PORÓWNANIE

Integracja wsadowa (batch)

Okresowe ładowanie dużych porcji danych według harmonogramu. Niższe obciążenie źródeł, lecz opóźnienia w aktualności; klasyczny ETL zwykle raz na dobę.

Integracja strumieniowa (real-time)

Stały napływ rekordów i natychmiastowe aktualizacje. Wymaga kolejek zdarzeń i przetwarzania strumieniowego; niskie opóźnienia kosztem złożonej architektury.

Wybór i podejście mieszane

Szybkozmiennie dane strumieniowo; referencyjne i finansowe wsadowo. Platformy łączą tryby: pełny wsad historyczny + ciągłe zmiany (delta).



TRYB INTEGRACJI: PODEJŚCIE MIESZANE

Batch vs. streaming – wybór

Wiele organizacji łączy tryby: dane szybkozmienne (status przesyłki, IoT) strumieniowo dla aktualności, a duże tabele referencyjne i finansowe wsadowo, by nie przeciążać źródeł.

Przetwarzanie delta

Nowoczesne platformy (np. Spark, Kafka) wspierają model: pełny wsad historyczny, a następnie dopływ zmian w trybie ciągłym, łącząc hurt danych z bieżącą synchronizacją.





ŹRÓDŁA DANYCH I ICH INTEGRACJA

INTEGRACJA ŹRÓDEŁ DANYCH


170+

Nowoczesne platformy integracyjne oferują ponad 170 konektorów do źródeł danych – od baz, plików i API po kolejki – umożliwiając automatyczny załadunek do Lakehouse/Data Lake.

Kluczem jest dobór właściwej metody integracji zgodnie z wymaganiami świeżości danych.



EXTRACT TRANSFORM LOAD



EXTRACT LOAD TRANSFORM



ETL VS ELT INTEGRATION

Klasyczne ETL

Transformacje przed załadunkiem; wysoka kontrola jakości i zgodność schematu. Działa wsadowo, wymaga zasobów staging i serwerów ETL.

Nowoczesne ELT

Najpierw ładowanie surowych danych, transformacje w platformie docelowej. Skalowalne, elastyczne, upraszcza infrastrukturę lakehouse.

Kiedy które wybrać?

ETL dla rygorystycznych, ustrukturyzowanych danych i kontroli.
ELT dla szybkości, skali i ponownego przetwarzania w chmurze.

CDC: SYNCHRONIZACJA ZMIAN DANYCH

Log-based CDC

Odczyt dzienników transakcyjnych (np. binlog, WAL) pozwala wychwycić wstawienia, aktualizacje i usunięcia z minimalnym narzutem na źródło oraz szybkim przekazaniem zmian do Lakehouse/Hurtowni.

Znaczniki czasu i migawki

Pobieranie rekordów zmienionych od ostatniego timestampu jest proste, ale zwykle nie obejmuje usunięć; wymaga dodatkowych tabel zmian lub soft-delete, by zachować spójność.

Wyzwalacze (triggers)

Zmiany są zapisywane do tabeli dziennika i odczytywane przez ETL, lecz zwiększają obciążenie źródła; stosowane rzadziej, gdy ważna jest wydajność operacyjna.



INTEGRACJA PRZEZ API

Na czym polega

Programowe wywoływanie endpointów w celu pobierania/wysyłania danych z usług SaaS i partnerów oraz włączania ich do platformy analitycznej. Tryby: batch/incremental, webhooks dla near real-time.

Zalety

Dostęp do danych niedostępnych na poziomie bazy/pliku; bieżące informacje; standaryzacja przez REST/JSON i spójne metody (GET/POST) upraszczające integrację wielu źródeł.

Wyzwania i praktyki

Limity i paginacja; uwierzytelnianie (OAuth, tokeny) i retry; coupling i koszty. Stosuj incremental/cache, API Gateway, oraz asynchroniczność (webhook/stream) gdy to możliwe.





ARCHITEKTURA ZDARZENIOWA KOLEJEK

Technologie

RabbitMQ/IBM MQ/ActiveMQ; Kafka/Event Hubs/Kinesis; Azure Service Bus/Google Pub/Sub.

Zalety kolejek

Asynchroniczność i luźne powiązanie, wysoka skalowalność, wielu konsumentów (pub-sub), buforowanie pików ruchu.

Wyzwania i zastosowania

Złożoność i zgodność transakcyjna (exactly-once), opóźnienia mikro-batch. Zastosowania: mikroserwisy, IoT/telemetry, DWH near-real-time, buffering między batch i stream.

WIRTUALIZACJA DANYCH I ZAPYTANIA FEDEROWANE

Wirtualizacja danych

Wspólny widok bez kopiowania: dane pozostają w źródłach, a warstwa abstrakcji łączy je on demand. Zapewnia aktualność (real-time), szybkie integracje ad-hoc i jednolity dostęp (SQL/API) dla biznesu.

Wyzwania i ograniczenia

Wydajność przy dużej skali, obciążenie systemów źródłowych, potrzeba modeli i metadanych, oraz ograniczenia wspólnego języka.

Optymalizacje: push-down, cache, materializacja fragmentów wyników.

Zapytania federowane

Jedno zapytanie łączące wiele źródeł (np. BigQuery, Presto/Trino, Linked Servers). Proste dla użytkownika, lecz zależne od planu wykonania;

świetne do szybkiej integracji, obok fizycznego Lakehouse.



PORÓWNANIE

Metoda	Charakter	Wydajność i świeżość	Koszty	Złożoność	Elastyczność	Typowe zastosowania
ETL	Batch; transform przed załadunkiem	Wysoka dla dużych batch (hurtowe przetwarzanie), ale wysoka latencja (dane np. raz dziennie).	Wymaga osobnych narzędzi/serwerów w ETL (licencje, infrastruktura).	Średnia – dojrzałe narzędzia, ale potrzeba specjalistów ETL i pielęgnacji pipeline.	Niska – sztywne, schemat i logika ustalone z góry; trudno szybko zmienić transformacje ex post.	Hurtownie danych, regularne raporty BI, dane krytyczne wymagające walidacji przed załadunkiem.
ELT	Batch; load surowych, transform w docelowym	Wydajne dla big data (wykorzystuje moc docelowej platformy); latencja zależy od harmonogramu (może być godzinowa lub częstsza).	Mniej dodatkowej infrastruktury – używa mocy np. chmury; większe koszty storage (przechowywane surowe + przetworzone).	Średnia – prostszy pipeline, ale wymaga zarządzania w platformie docelowej (np. skrypty SQL/Spark).	Wysoka – zachowanie surowych danych umożliwia ponowne przetwarzanie i inne wykorzystanie w przyszłości.	Data Lakehouse, analizy AI/ML, często przy integracji półustrukturyzowanych danych; chmurowe hurtownie (Snowflake, BigQuery).

Metoda	Charakter	Wydajność i świeżość	Koszty	Złożoność	Elastyczność	Typowe zastosowania
CDC (technika)	Ciągłe (streaming) lub micro-batch	Bardzo niska latencja – dane prawie na bieżąco; wydajne, bo przesyła tylko zmiany.	Średnie – redukuje transfer i przetwarzanie (oszczędność), ale wymaga narzędzi CDC (często licencje komercyjne) lub dodatkowego utrzymania.	Wysoka – implementacja i utrzymanie CDC jest złożone, potrzeba obsługi logów/triggers i mechanizmów gwarantujących spójność.	Średnia – ograniczone do źródeł, które wspierają logi/zmiany; dobrze integruje się z istniejącymi ETL/ELT jako dodatek.	Szybka synchronizacja baz OLTP z Lakehouse/hurtownią; śledzenie zmian w danych klientów, stanów zamówień itp. w czasie zbliżonym do rzeczywistego.
API (integracja przez usługi)	Batch lub near-real (polling / webhook)	Średnia – zależy od API; pojedyncze wywołania wolniejsze niż dostęp do bazy (HTTP, overhead). Nie nadaje się do mega wolumenów bez paging. Aktualność dobra, jeśli polling częsty lub webhook.	Niewielkie koszty infrastruktury (wykorzystuje istniejące API), ale potencjalne koszty opłat za API od dostawcy.	Średnia – potrzeba zaimplementować logikę wywołań API, obsługi błędów, autoryzacji; narzędzia iPaaS to upraszczają.	Wysoka – można sięgnąć po niemal dowolne dane udostępnione przez zewnętrzne serwisy; integracja wielu różnych źródeł usługowych.	Pobieranie danych z aplikacji SaaS (CRM, ERP w chmurze), zewnętrznych serwisów (pogoda, mapy), integracja z partnerami przez wymianę usług.

Metoda	Charakter	Wydajność i świeżość	Koszty	Złożoność	Elastyczność	Typowe zastosowania 100
Kolejki / Message Broker	Streaming (asynchroniczne, zdarzeniowe)	Bardzo wysoka przepustowość, niskie opóźnienia (ms-s) – idealne do real-time stream. Wymaga konsumentów skalujących się by przetworzyć napływ.	Wyższe – konieczne utrzymanie brokera (Kafka itp.) lub opłaty za usługę zarządzaną; koszty przetwarzania ciągłego (zawsze aktywne konsumenci).	Wysoka – architektura event-driven jest złożona; wymaga solidnego monitoringu i zapewnienia dokładnego przetworzenia.	Wysoka – systemy luźno połączone, możliwość łatwego dodawania nowych odbiorców danych, elastyczne scenariusze przetwarzania (stream, okna czasowe, itd.).	Integracja mikroserwisów i IoT; stream analytics; sytuacje wymagające skalowalności i decouplingu: duże strumienie zdarzeń, konieczność aktualizacji danych w ułamku sekundy (np. wykrywanie fraudów,).
Wirtualizacja danych	Zapytania na żywo, brak kopiowania	Zróżnicowana – dobre czasy dla prostych zapytań i małych zestawów; przy dużych zapytaniach spadek wydajności (bo łączy on-the-fly). Dane zawsze aktualne prosto ze źródeł.	Niskie koszty składowania (brak duplikacji danych); mogą być koszty licencji narzędzia wirtualizacji.	Średnia – mniej prac ETL, ale wymaga zdefiniowania logicznej warstwy i zarządzania dostęпами.	Bardzo wysoka – dowolne łączenie danych na żądanie, szybkie dodawanie nowych źródeł do widoku; ograniczenie: źródła muszą być dostępne i znane strukturalnie.	Szybkie scalenie danych z różnych silosów na potrzeby jednorazowych analiz lub raportów, dostęp do danych wrażliwych bez kopiowania (governance), łączenie rozproszonych źródeł w czasie rzeczywistym (np. widok 360° klienta adhoc).

PORÓWNANIE

Metoda	Charakter	Wydajność i świeżość	Koszty	Złożoność	Elastyczność	Typowe zastosowania
Zapytania federowane	Zapytania rozproszone (silnik łączy źródła)	Podobnie jak wirtualizacja: zależne od zapytania. Lepsze dla mniejszych zapytań, bo minimalny narzut planowania. Dla dużych zbiorów – może być wolno.	Często wbudowane w silnik SQL (brak dodatkowych opłat poza ewent. większym zużyciem mocy); brak kosztów składowania.	Średnia – wymaga konfiguracji połączeń między systemami i przeszkolenia użytkowników jak pisać zapytania do różnych źródeł.	Wysoka – daje użytkownikom jednolity język (np. SQL) do różnych źródeł; nie wymaga budowy pipeline, więc szybko adaptuje się do nowych pytań.	Sprawozdawczość łącząca dane z wielu systemów bez centralnego magazynu; uzupełnienie hurtowni o dane w locie (np. rzadko używane szczegóły); migracje – tymczasowo zapytania łączone stary system + nowy.

PORÓWNANIE METOD INTEGRACJI

Wydajność i latencja

ETL/ELT skalują się przy dużych wolumenach, ale zwiększają latencję. CDC i broker zapewniają niskie opóźnienia oraz aktualność danych.

Elastyczność integracji

Wirtualizacja danych, zapytania federowane i API szybciej adaptują się do nowych źródeł i zmian w ekosystemie.

Koszty i utrzymanie

Nakłady zależą od metody: infrastruktura dla ETL i brokerów vs. niższe koszty przy wirtualizacji i federacji.



The background is a dark, blurred image. On the left, a person is visible from the chest up, sitting at a desk and looking at a computer screen. The person's face is not clearly visible. In the center, there is a large, dark rectangular shape, possibly a screen or a piece of furniture. On the right, there is a light-colored cloud icon. The overall tone is dark and professional.

PRAKTYKI I TRENDY INTEGRACJI

NOWOCZESNE TRENDY W INTEGRACJI

Lakehouse: jedna platforma

Konsolidacja lake i warehouse w architekturę Lakehouse z warstwami Bronze/Silver/Gold, transakcjami i schematem (Delta, Iceberg, Hudi) dla SQL, Spark, BI i AI.

Streaming: real-time by default

Projektuj integracje strumieniowe (CDC) z Kafka/Flink/Spark; batch jako uzupełnienie. Architektury Kappa/Lambda zwiększają świeżość i przewagę biznesową.

Zero-ETL i automatyzacja

Natywna replikacja między systemami (Fabric Mirroring, Snowflake, Synapse Link), Low-Code/No-Code i Copiloty skracają czas tworzenia pipeline'ów.

DataOps: CI/CD dla danych

Pipelines jako kod, testy automatyczne, orkiestracja i monitoring (Airflow, ADF, GitHub Actions) zwiększają niezawodność i tempo zmian.



NOWOCZESNE TRENDY W INTEGRACJI

Metadane i katalog

Centralne katalogi (Purview, Glue) wspierają generowanie integracji, klasyfikacje i lineage; rejestruj źródła, pipelines i opisy biznesowe.

AI w integracji

Dopasowanie schematów, uzupełnianie braków, wykrywanie anomalii oraz generowanie pipeline'ów – wsparcie inżynierów, nie substytut metodyk.

Governance w centrum

Własność danych, słowniki, komitety i kontrola dostępu (Unity Catalog, Lake Formation, Purview) budują zaufanie i zgodność.





WNIOSKI I REKOMENDACJE



KLUCZOWE ZALECENIA INTEGRACJI

Integracja hybrydowa: batch + streaming

Łącz ETL/ELT do dużych wsadów oraz CDC/streaming do bieżących zmian. Dobierz metodę do źródła: bazy (CDC), pliki (wsad), API (konektory/Cache), IoT (kolejki i stream).


Bezpieczeństwo i zgodność od początku

Klasyfikuj PII i dane krytyczne, szyfruj i maskuj, kontroluj dostęp rolami, audytuj. Zapewnij zgodność (np. RODO, mechanizmy usunięcia danych). Używaj katalogów typu Purview.

DataOps, skalowalność i jakość danych

Wersjonuj pipeline'y, testuj schemy, wdrażaj CI/CD i monitoruj anomalie. Projektuj modułowo i skalowalnie w chmurze. Waliduj jakość, raportuj błędy, kataloguj metadane i standaryzuj definicje.

DANE W MICROSOFT FABRIC



MECHANIZM SHORTCUTS – INTEGRACJA BEZ KOPIOWANIA DANYCH

Mechanizm Shortcuts w OneLake

Shortcuts pozwalają podłączyć zewnętrzne źródła danych do OneLake bez kopiowania ich fizycznie.

Dostęp w native format


Dane są dostępne w ich oryginalnym formacie bez narzutu konwersji, co zwiększa efektywność.

Wsparcie hybrydowej integracji

Umożliwia analizę danych historycznych bez migracji do nowego systemu, wspierając hybrydowe środowiska.

Rozszerzona funkcjonalność 2025

Nowości to wsparcie dla Azure Blob Storage i planowane skróty do danych on-premises przez bramy danych.



PRZEGLĄD NARZĘDZI INTEGRACYJNYCH W MICROSOFT FABRIC

Kompleksowa integracja danych

Microsoft Fabric umożliwia integrację danych z różnych źródeł, zarówno wewnętrznych, jak i zewnętrznych, do Lakehouse.

Integracja wsadowa (Batch)

Metoda wsadowa pozwala na okresowe przetwarzanie dużych zbiorów danych z systemów ERP, CRM i raportów Excela.

Integracja w czasie rzeczywistym

Integracja real-time obsługuje strumieniowe dane z czujników IoT oraz API partnerów dla natychmiastowej analizy.



KONEKTORY DANYCH I MOŻLIWOŚCI DATA FACTORY

Centralny moduł Data Factory

Data Factory to kluczowy komponent platformy Fabric do orkestracji i integracji przepływów danych.

Ponad 200 konektorów danych

Biblioteka zawiera ponad 200 konektorów do różnych systemów SQL, NoSQL, plików i usług SaaS.

Wsparcie różnych źródeł danych

Konektory obsługują bazy danych, magazyny plików, aplikacje biznesowe oraz protokoły API jak REST i HTTP.



TWORZENIE PIPELINE'ÓW ETL/ELT I ICH ZASTOSOWANIA

Tworzenie graficznych workflow

Data Factory umożliwia tworzenie pipeline'ów z operacjami ETL/ELT, takimi jak kopiowanie, transformacja i ładowanie danych.

Zaawansowane funkcje pipeline'ów

Pipeline'y oferują planowanie, wyzwalacze, warunki, pętle, rozgałęzienia logiki oraz monitorowanie wykonania zadań.

Scenariusze integracji wsadowej

Typowym zastosowaniem jest cykliczne zasilanie Lakehouse danymi z systemów ERP lub migracja hurtowni danych do Fabric.

Integracja z chmurami zewnętrznymi

Data Factory pozwala kopiować dane z zewnętrznych chmur, takich jak Amazon S3 czy BigQuery, do Lakehouse w OneLake.



ZALETY PODEJŚCIA DATA FACTORY

Minimalny wysiłek deweloperski

Integracje buduje się konfiguracyjnie, bez potrzeby pisania kodu, przez łatwe wyklikiwanie kroków w pipeline.

Gotowe konektory out-of-the-box

Dostępne konektory eliminują konieczność samodzielnego implementowania wywołań API i sterowników baz danych.

Zarządzane, skalowalne i bezpieczne pipeline'y

Pipeline'y są w pełni zarządzane, skalowalne i korzystają z zabezpieczeń, takich jak Managed Identity zamiast haseł.



MODELOWANIE DANYCH I UNIFIKACJA SCHEMATÓW

**MODELOWANIE DANYCH
TO PROCES PROJEKTOWANIA
STRUKTURY BAZY DANYCH TAK, ABY
ODZWIERCIEDLAŁA ZASADY
BIZNESOWE I RELACJE POMIĘDZY
INFORMACJAMI.**

MODELOWANIE DANYCH W HURTOWNI

- Opiera się na **modelu zorientowanym na analizę** – często stosuje się **schemat gwiazdy** (fakt i wymiary) lub **Data Vault** do integracji wielu źródeł.
- Kluczowym celem jest stworzenie jednego, wspólnego obrazu najważniejszych bytów (np. Klient, Produkt, Transakcja) – czyli tzw. **jednej wersji prawdy**.
- Przy budowie hurtowni dużo uwagi poświęca się **unifikacji schematów**: dane z różnych systemów operacyjnych mapowane są do wspólnego zestawu tabel i pól.
 - Przykładowo, jeżeli w jednym systemie mamy pole CustomerID, a w innym ClientNr, to w hurtowni zostaną one zunifikowane jako jednolite **KlientID**.
- Modelowanie wymaga ścisłej współpracy z ekspertami domenowymi, aby zrozumieć znaczenie danych i zaprojektować **spójny schemat**.

SCHEMAT GWIAZDY

- **Tabele wymiarów** opisują encje biznesowe: produkt, klient, miejsce czy czas. Zawierają one kolumnę klucza głównego i atrybuty służące do filtrowania i grupowania danych
- **Tabele faktów** przechowują obserwacje (np. zamówienia, pomiary) i zawierają klucze obce odnoszące się do tabel wymiarów oraz pola liczbowe (miary). **Granularność faktu** zależy od kombinacji kluczy wymiarów. Tabele faktów rosną znacznie szybciej niż wymiary.
- *Normalizacja* oznacza przechowywanie danych w sposób ograniczający redundancję; *denormalizacja* łączy dane w jedną tabelę dla uproszczenia i wydajności.
- Rzadziej stosuje się **schemat płatka śniegu (snowflake)**, w którym tabele wymiarowe są znormalizowane. Taki wariant może utrudniać nawigację i pogarszać wydajność zapytań.
- Projektując modele danych (np. semantic models w Power BI lub w Synapse), **zastosowanie schematu gwiazdy poprawia wydajność, ułatwia filtrowanie, grupowanie i tworzenie miar**.
- W praktyce ważne jest też stosowanie kluczy substytutów i implementacja powolnych zmian wymiarów (Slowly Changing Dimensions) w razie potrzeby.

MODELOWANIE DANYCH W LAKEHOUSE

- W architekturze **lakehouse** modelowanie bywa bardziej **iteracyjne i elastyczne**.
- Na początku dane mogą być załadowane w formie zbliżonej do źródeł (strefa Bronze).
- Dopiero na poziomie Silver/Gold projektuje się docelowe struktury.
- Najlepsze praktyki sugerują stosowanie podobnych konceptów jak w hurtowniach – np. **modeli wielowymiarowych lub faktowo-wymiarowych** w warstwie złotej (Gold), ale osiągniętych w inny sposób.
- Zamiast materializować je w oddzielnej bazie, tworzy się np. **widoki** lub tabele posortowane według wymiarów w lakehouse.
- Unifikacja schematów odbywa się więc w trakcie przekształcania danych: **różne surowe schematy są transformowane do spójnego modelu pośredniego**.

UNIFIKACJA SCHEMATÓW

- **Unifikacja schematów** oznacza zapewnienie, że dane z różnych źródeł czy domen pasują do wspólnego słownika pojęć i struktury. W praktyce obejmuje to:
 - **Konwencje nazewnnicze:** ustalenie jednolitego nazewnictwa kolumn, encji itp. (np. zawsze DataTransakcji zamiast naprzemiennie Date / TransDate).
 - **Mapowanie encji i atrybutów:** np. standaryzacja kodów krajów do jednego formatu, ujednolicenie jednostek miar, słowników (np. jedna tabela „Produkt” łącząca asortyment z różnych systemów).
 - **Integrację kluczy głównych:** stworzenie wspólnych identyfikatorów (np. klucz klienta ujednolicony przez deduplikację i przypisanie globalnego ID).

UNIFKACJA SCHEMATÓW

HURTOWNIA

- **Projektowana z góry** – definiuje się *Enterprise Data Model*.
- Przykładem takiego podejścia jest **Common Data Model (CDM)** firmy Microsoft, czyli zestandaryzowany zestaw definicji encji biznesowych (jak Klient, Konto, Zamówienie) używany w Dynamics 365 i Power Platform.
- Wykorzystanie takiego wzorca ułatwia integrację – aplikacje dzielą wspólny język danych, co upraszcza zasilanie hurtowni i lakehouse.
- Jak wskazują dokumentacje, **użycie wspólnego modelu danych znacząco skraca czas potrzebny na zrozumienie i połączenie danych z różnych aplikacji.**

LAKEHOUSE

- Osiągana **stopniowo**.
- Na przykład, dane klienckie z kilku plików CSV o różnym układzie mogą zostać wczytane do strefy Bronze „jak leci”. Następnie, w strefie Silver, budujemy jeden **ujednolicony widok Klient** z wyborem i przemianowaniem kolumn do wspólnego formatu oraz z uzupełnieniem brakujących wartości (np. standaryzacja adresów). Taki przekształcony schemat posłuży już całej organizacji.
- Dzięki temu podejściu ELT, możemy najpierw **szybko załadować** nowe dane, a dopiero potem zadbać o ich integrację schematu, gdy będzie jasne jak je wykorzystać.

ZNACZENIE CENTRALNEGO SŁOWNIKA DANYCH I SPÓJNOŚCI



Unifikacja schematów danych

Dobra unifikacja schematów zwiększa spójność oraz zaufanie do danych użytkowników końcowych.


Centralny słownik danych (Business Glossary)

Posiadanie centralnego słownika danych zapewnia jednolite definicje kluczowych bytów w organizacji.

Spójność i wiarygodność danych

Ujednolicone podejście do danych skutkuje większą spójnością, dokładnością i łatwością analiz.

ZARZĄDZANIE OPERACYJNE, ZMIANY SCHEMATÓW I ORKIESTRACJA



Zarządzanie operacyjne systemów

W hurtowniach danych zarządzanie obejmuje harmonogramowanie ETL, monitorowanie zapytań SQL i zarządzanie serwerem. W lakehouse dodaje się kontrolę klastrów i monitorowanie potoków danych.

Zarządzanie zmianami schematów

Zmiany schematów wymagają planowania migracji i wersjonowania. Integracja z DevOps i narzędzia jak Flyway usprawniają kontrolę i wdrażanie zmian.

Zarządzanie zmianami w lakehouse

Lakehouse ułatwia zmiany schematów dzięki schema-on-read, ale transformacje podlegają wersjonowaniu i kontroli kodu przez Git.

Narzędzia integracji i orkiestracji

Azure Data Factory i Fabric umożliwiają tworzenie graficznych pipeline'ów, integrację źródeł i orkiestrację zadań, także w trybie zdarzeniowym.

NAJWIĘKSZE WYZWANIA



Obsługa danych strumieniowych

Nowoczesne systemy obsługują ciągły napływ danych, jak zdarzenia IoT i logi, integrując je z hurtowniami i lakehouse.

Integracja streaming w Lakehouse

Technologie takie jak Apache Spark i Azure Stream Analytics umożliwiają bezpośrednie zapisywanie danych strumieniowych do tabel delta w OneLake.

Monitoring i optymalizacja systemów

Monitorowanie przepływu danych i zasobów systemowych jest kluczowe dla stabilności i wydajności produkcyjnych środowisk danych.

Automatyczna rekonfiguracja i skalowanie

Automatyczne skalowanie i rekonfiguracja systemów zapewniają wysoką dostępność i optymalną wydajność w czasie rzeczywistym.

**NAJLEPSZE PRAKTYKI:
JAKOŚĆ, GOVERNANCE I
WYDAJNOŚĆ**

STREFY DANYCH, DOKUMENTACJA I JAKOŚĆ U ŹRÓDŁA



Podział stref danych

Wyraźny podział na strefy Bronze, Silver i Gold ułatwia unifikację schematów i izoluje surowe dane od użytkowników końcowych.

Standardyzacja i dokumentacja schematu

Przygotuj słownik danych z kluczowymi encjami i spójnym nazewnictwem, opisując tabele i pola, aby uniknąć błędnej interpretacji.

Jakość danych u źródła

Waliduj i czyść dane przed załadunkiem, monitoruj metryki jakości i automatycznie koryguj proste błędy, aby zwiększyć zaufanie do systemu.

MONITORING, ZARZĄDZANIE ZMIANAMI I BEZPIECZEŃSTWO



Monitoring procesów danych

Pipeline powinien logować ilość rekordów, czas trwania i błędy, z alertami o odchyleniach powyżej 20%.

Zarządzanie wersjami danych

Wersjonowanie wymiarów i przechowywanie surowych kopii danych zapewnia zgodność historyczną i elastyczność modelu.

Zarządzanie danymi i governance

Model federacyjny z centralnym zespołem ustala standardy, a domeny odpowiadają za swoje dane pod nadzorem polityk dostępu.

Bezpieczeństwo i prywatność danych

RBAC i szyfrowanie chronią dane osobowe, a anonimizacja maskuje wrażliwe informacje w początkowych fazach przetwarzania.

OPTIMALIZACJA WYDAJNOŚCI I KOSZTÓW



Partycjonowanie danych

Dzielenie dużych tabel faktów po kluczach filtrów, jak data, poprawia szybkość zapytań i efektywność.

Format kolumnowy i kompresja

Używanie Parquet lub Delta zmniejsza czas odczytu i rozmiar plików dzięki kompresji i formatowi kolumnowemu.

Cache'owanie i materializacja

Cache'owanie często używanych danych i tworzenie tabel agregatów przyspiesza analizy i zmniejsza obciążenie systemu.

Zarządzanie kosztami chmury

Monitoruj zużycie i koszty, planuj zadania poza szczytem oraz usuwaj nieużywane zasoby, by minimalizować wydatki.



TESTOWANIE, EDUKACJA I PROMOWANIE DOBRYCH PRAKTYK

Testowanie wydajności systemu

Przed uruchomieniem testuj wydajność i skalowalność systemu na realistycznych scenariuszach, aby wykryć wąskie gardła.

Optymalizacja pipeline ETL

Monitoruj i skracaj czas działania pipeline ETL, aby zapewnić codzienną aktualizację danych bez opóźnień.

Edukacja i szkolenia zespołu

Regularnie szkol analityków, by rozumieli model danych, tabele i definicje miar, poprawiając interpretację danych.

Promowanie odpowiedzialności danych

Ustanów jasne wytyczne dotyczące dostępu i udostępniania danych, wspierając politykę bezpieczeństwa i klasyfikację danych.

WNIOSKI I REKOMENDACJE DLA ORGANIZACJI

PODSUMOWANIE PODEJŚĆ I REKOMENDACJE STRATEGICZNE



Komplementarność hurtowni i lakehouse

Hurtownie danych oferują uporządkowane dane z góry zdefiniowanymi schematami dla łatwego raportowania. Lakehouse integruje dane ustrukturyzowane i nieustrukturyzowane, umożliwiając zaawansowane analizy i AI.

Rekomendacje wdrożeniowe

Zaleca się architekturę hybrydową łączącą hurtownię i lakehouse, zaczynając od małych projektów pilotażowych dla stopniowej transformacji.

Zarządzanie jakością danych

Dbanie o Data Governance i spójność danych jest kluczowe, by uniknąć chaosu i zapewnić zaufanie do danych w lakehouse.

Optymalizacja kosztów i wydajności

Skalowalność horyzontalna i monitorowanie kosztów zapewniają efektywność inwestycji oraz odpowiednią wydajność systemu.

PROCES PRZYGOTOWANIA DANYCH DLA MODELI AI

Znaczenie dokładnych i czystych danych dla sukcesu AI




AI TO DANE!!




+ Uczenie
maszynowe

=



+ AI

=



+ Generatywna
AI

=



KLUCZOWE ASPEKTY JAKOŚCI DANYCH W PROJEKTACH AI



Kompletność danych

Brak braków w danych zapewnia pełną podstawę do analiz i prognoz w projektach AI.

Spójność danych

Zgodność danych między źródłami zapobiega błędom i zapewnia wiarygodność wyników.

Aktualność danych

Dane muszą być aktualne, aby modele AI były skuteczne i nie wykazywały dryfu.

Dokładność danych

Wysoka precyzja danych minimalizuje błędy i zwiększa wartość biznesową projektów AI.

WAGA ZAGADNIENIA

Czas na przygotowanie danych

80%

tyle czasu pracy specjalistów DS zajmuje
czyszczenie i przygotowanie danych

Koszt złej jakości danych

12,9 mln USD

średni roczny koszt dla przedsiębiorstwa (według
analizy Gartnera)

Poprawa modelu dzięki jakości

+20%

wzrost skuteczności modelu AI po oczyszczeniu danych (przykład firmy Automotus)

ZNACZENIE JAKOŚCI DANYCH

KOMPLETNOŚĆ, SPÓJNOŚĆ I WPŁYW NA MODELE AI

Znaczenie kompletności danych

Kompletność danych zapewnia dostęp do wszystkich niezbędnych atrybutów, co zapobiega błędom analizy i prognoz.

Znaczenie spójności danych

Spójność danych gwarantuje zgodność między źródłami, eliminując chaos i ułatwiając integrację danych.

Wpływ jakości danych na modele AI

Niska jakość danych może prowadzić do dryfu modeli, zmniejszenia dokładności i wzrostu błędów w AI.

Procesy zapewniania jakości danych

Walidacja, profilowanie i kontrola metadanych minimalizują ryzyko i maksymalizują wartość biznesową danych.

Plan




EXPLORATORY DATA ANALYSIS – EDA

EXPLORATORY DATA ANALYSIS

- Exploratory Data Analysis obejmuje metody statystyczne i wizualizacyjne pozwalające podsumować główne cechy danych, wykryć błędy i zrozumieć, czy zbiór jest gotowy do dalszych faz przetwarzania.
- Pomaga:
 - **Zbadać strukturę danych** – identyfikować wzorce i trendy, wykrywać anomalie, badać zależności między zmiennymi i testować hipotezy.
 - **Informować proces czyszczenia i przetwarzania** – wyniki EDA wpływają na wybór technik przygotowania danych i algorytmów uczenia.
 - **Dobierać model i miary** – np. ocenić, czy rozkład jest liniowy, czy nierównowagi klas wymagają innych metryk.

TECHNIKI EDA

- **Statystyki opisowe** – średnia, mediana, odchylenie standardowe, maksimum/minimum itp. do szybkiego podsumowania rozkładu.
- **Wizualizacje** – histogramy, wykresy pudełkowe (box plots), diagramy rozrzutu i gęstości; ukazują rozkłady, zależności i wartości odstające.
- **Analiza korelacji** – obliczanie macierzy korelacji i tworzenie map ciepła, aby zbadać siłę zależności między zmiennymi.
- **Zaawansowane techniki** – analiza składowych głównych (PCA) czy klasteryzacja do odkrywania ukrytej struktury.



PROFILOWANIE DANYCH I STATYSTYKI OPISOWE



Profilowanie danych i statystyki opisowe – pierwszy krok do jakości

- **Profilowanie danych** to eksploracja i podsumowanie zbioru danych za pomocą statystyk, aby szybko ujawnić oczywiste problemy jakościowe.
- Analizowane są m.in.:
 - rozmiar zbioru,
 - liczba brakujących wartości,
 - rozkłady liczbowych pól (średnia, min, max, odchylenie standardowe),
 - najczęstsze wartości w kolumnach kategoriowych,
 - liczba duplikatów.
- Profilowanie odpowiada na pytania:
 - Czy występują luki w danych?
 - Czy wartości mieszczą się w spodziewanych zakresach?
 - Czy rozkład danych wygląda logicznie?
- **Przykład:** Jeśli w kolumnie „wiek” średnia wynosi 45 lat, min = 0, a max = 200, to od razu widać potencjalne błędy (wiek 0 lub 200 lat jest podejrzany).
- **Statystyki opisowe** pozwalają wykryć wartości odstające (outliers), np. transakcje o podejrzenie wysokiej kwocie, które mogą wskazywać błędy lub wyjątkowe przypadki.
- Rezultatem profilowania jest ustalenie bazowej „punktacji” jakości danych i lista oczywistych problemów do naprawy.
- Narzędzia do profilowania generują raporty z informacjami typu: procent braków na kolumnę, najczęstsze wartości, liczba duplikatów – to punkt wyjścia do dalszych działań naprawczych.

WALIDACJA I INTEGRALNOŚĆ DANYCH

Walidacje techniczne i formalne

Pierwszy poziom walidacji to sprawdzanie formatu dat, poprawności e-maili oraz innych wymagań technicznych danych.

Przykłady: czy pola dat mają poprawny format i prawdziwe daty (np. nie istnieje 30 luty) , czy kod produktu pasuje do wzorca i istnieje w słowniku produktów , czy wiek osoby nie jest ujemny ani zbyt wysoki, czy adres e-mail zawiera "@"


Reguły biznesowe i logika

Drugi poziom obejmuje sprawdzanie sensu danych oraz logicznych powiązań między nimi zgodnie z regułami biznesowymi.

Przykłady: pole status zamówienia może przyjmować tylko jedną z dozwolonych wartości (np. "złożone", "wysłane", "zrealizowane") – wszelkie inne wartości są błędem; data zakończenia nie może poprzedzać daty rozpoczęcia; rezerwacja hotelu nie może mieć długości ujemnej

Lista naruszeń do poprawy

Efektem walidacji jest lista błędów i naruszeń, które wymagają korekty lub uzasadnienia przez użytkownika.



WALIDACJA I INTEGRALNOŚĆ DANYCH - NARZĘDZIA

GX - GREAT EXPECTATIONS

great expectations

PLATFORM SOLUTIONS RESOURCES COMPANY Try GX Cloud Log in

Get started with GX Cloud by joining our bi-weekly hands on workshop.

Everything you need to trust your data

GX helps data teams catch problems early, keep stakeholders aligned, and deliver reliable data for every decision.

Get everything you need to ensure governance & trust in AI with data quality working in your favor.

Get started with GX Cloud

Logos: PAK, SNOWFLOW, avanade, GitHub, Tai.com

Great Expectations

MICROSOFT PURVIEW DATA QUALITY



Data Quality in Microsoft Purview Unified Catalog

TWORZENIE I SELEKCJA CECH (FEATURE ENGINEERING)

FEATURE ENGINEERING

- Polega na wykorzystaniu wiedzy domenowej do tworzenia lub transformacji cech z surowych danych, co zwiększa zdolność modelu do rozpoznawania zależności.
- Głównym celem jest maksymalizacja mocy predykcyjnej algorytmów poprzez przekształcanie danych w informatywne cechy.
- Ważne jest rozróżnienie:
 - **Ekstrakcja cech** – tworzenie nowych zmiennych z istniejących (np. z daty wydobywanie dnia tygodnia lub godziny).
 - **Selekcja cech** – wybór najbardziej istotnych zmiennych, aby zmniejszyć wymiarowość i poprawić działanie modelu.
 - **Skalowanie i normalizacja** – standaryzacja zakresów zmiennych (min-max, z-score), szczególnie gdy algorytmy wykorzystują odległości.
 - **Transformacja cech** – stosowanie przekształceń matematycznych (logarytmicznych, pierwiastkowych, potęgowych) w celu zmniejszenia skośności lub nadania liniowości.
- W praktyce często należy łączyć wiele technik (np. ekstrakcję i transformację), aby zbudować bogaty zbiór cech.

PRZYKŁADY

- **Czasy i szeregi czasowe** – tworzenie opóźnień (lagów), ruchomych średnich i odchyleń standardowych, a także dekompozycja sezonowa. W modelach prognoz (np. zapotrzebowania na energię) takie cechy wzbogacają dane o kontekst historyczny.
- **Zmienne kategoryczne** – kodowanie zmiennych na postać liczbową, np. one-hot encoding lub label encoding.
- **Tekst** – tokenizacja i wektoryzacja (np. TF-IDF) w celu reprezentacji dokumentów.
- **Skalowanie** – standardyzacja lub normalizacja dla algorytmów wrażliwych na skalę (np. kNN, metody gradientowe). Przykład: z użyciem `StandardScaler().fit_transform(X)`.



UZUPEŁNIANIE BRAKÓW DANYCH (MISSING DATA IMPUTATION)

PRZYCZYNY I KONSEKWENCJE BRAKÓW DANYCH

- Braki danych występują w rzeczywistych zbiorach wskutek błędów ludzkich, awarii urządzeń, problemów z oprogramowaniem czy celowych pominięć. Ich obecność zmniejsza liczbę użytecznych obserwacji, pogarsza dokładność modeli i może prowadzić do błędnych wniosków.
- Można wyróżnia trzy mechanizmy braków:

Mechanizm braków danych	Definicja	Konsekwencje/przykład
Missing Completely at Random (MCAR)	Brak danych niezależny od obserwowanych i nieobserwowanych zmiennych.	Losowe pominięcia w ankiecie (np. przypadkowe przeskoczenie pytania) mogą być bezpiecznie usuwane, choć zmniejszają próbę.
Missing at Random (MAR)	Prawdopodobieństwo braków zależy od innych obserwowanych zmiennych, lecz nie od wartości brakującej.	W badaniu dochodów starsi respondenci częściej pomijają pytanie o zarobki, ale pozostaje to niezależne od samego poziomu dochodu.
Missing Not at Random (MNAR)	Brak danych zależy od nieobserwowanych zmiennych lub samej brakującej wartości.	Osoby z ciężką depresją mogą unikać pytań o zdrowie psychiczne; wymaga to zaawansowanych technik imputacji.

TECHNIK IMPUTACJI

- **Średnia/mediana** – zastąpienie brakujących wartości średnią lub medianą z obserwacji. Proste i często stosowane w przypadku danych numerycznych, choć zniekształca wariancję.
- **Moda** – dla danych katégoricznych braki są zastępowane najbardziej częstą kategorią.
- **K-Nearest Neighbors (KNN)** – brakujące wartości są imputowane na podstawie sąsiedztwa przypadków o podobnych cechach; technika efektywna przy silnych korelacjach między zmiennymi.
- **Multiple Imputation/MICE** – generuje kilka zbiorów z imputacją opartą na modelach statystycznych (np. regresji) i uśrednia wyniki, co lepiej oddaje niepewność; stosowane w przypadku MAR/MNAR i rekomendowane przy poważniejszych brakach (przegląd literatury).
- **Zaawansowane metody (np. GAN, autoenkodery)** – w 2024–25 r. rozwinięto techniki oparte na modelach generatywnych, które uczą się rozkładu danych i umożliwiają bardziej precyzyjną imputację.

OBSTŁUGA WARTOŚCI ODSTAJĄCYCH (OUTLIER HANDLING)

WYKRYWANIE ANOMALII (OUTLIERÓW)

- Wartości odstające (outliers) to obserwacje znacząco odbiegające od pozostałych.
- Mogą wynikać z błędów pomiaru, problemów z wprowadzaniem danych lub rzeczywistej zmienności.
- Obecność takich punktów może zafałszować statystyki (średnią, wariancję) i prowadzić do błędnych wniosków.
- Rozpoznanie outliers wymaga analizy kontekstu; usunięcie prawdziwych, lecz rzadkich zdarzeń może zubożyć dane.

METODY WYKRYWANIA WARTOŚCI ODSTAJĄCYCH

- **Metoda Z-score** – oblicza liczbę odchyłeń standardowych danego punktu od średniej. Obserwacje przekraczające ± 3 SD są traktowane jako odstające. Metoda jest efektywna przy rozkładach bliskich normalnemu, lecz wrażliwa na inne ekstremalne wartości.
- **Metoda IQR (Interquartile Range)** – wyznacza dolną i górną granicę jako $Q1 - 1.5 \cdot IQR$ i $Q3 + 1.5 \cdot IQR$; punkty poza tym zakresem są outliers. Jest odporna na silne skośności i zalecana przy danych finansowych lub medycznych.
- **Analiza wizualna** – wykresy pudełkowe i wykresy rozrzutu pomagają szybko dostrzec ekstremalne punkty; analiza EDA wskazuje, czy obserwacje są błędne czy istotne.
- **Anomaly Detection** – moduły AI w Azure, takie jak **AI Anomaly Detector**, automatycznie wybierają odpowiedni algorytm (univariate lub multivariate) i wykrywają skoki, spadki czy zmiany trendu w szeregach czasowych.

POSTĘPOWANIE Z OUTLIERS

- **Usunięcie** – usuwanie obserwacji, jeśli są wynikiem błędu pomiarowego lub nie reprezentują docelowej populacji. Należy zachować ostrożność, aby nie stracić istotnych danych.
- **Transformacja** – logarytmiczna lub Box-Cox transformacja zmniejsza wpływ skrajnych wartości, zachowując wszystkie obserwacje. Można również stosować winsoryzację (zastąpienie outliers wartościami granicznymi).
- **Kategoria „inne”** – w problemach klasyfikacyjnych można przeklasyfikować outliers do osobnej klasy, aby model uczył się ich identyfikować.

REKOMENDACJE PRAKTYCZNE

- **Zawsze zaczynaj od EDA** – użyj opisowych statystyk i wykresów, aby poznać dane, wykryć błędy i ocenić rozkład. Analiza pozwala zdecydować, które cechy są istotne i jakich przekształceń wymagają.
- **Projektuj pipeline'y Feature Engineering** – wyraźnie definiuj kroki tworzenia cech, korzystaj z Azure ML Designer lub kodu/pipeline w Databricks; zapisuj transformacje, aby zapewnić replikowalność i ponowne użycie.
- **Identyfikuj i uzupełniaj braki zgodnie z mechanizmem** – dla MCAR rozważ usuwanie wierszy, dla MAR/MNAR stosuj imputację (średnia/mediana, moda, KNN, MICE). Testuj różne podejścia i weryfikuj ich wpływ na model. Monitoruj wskaźnik błędu po imputacji.
- **Wykrywaj i obsługuj outliers** – zaczynaj od wizualizacji. Jeśli outliers są wynikiem błędu, usuń je; jeśli reprezentują rzadkie przypadki, rozważ transformacje lub utworzenie osobnej klasy. W Azure użyj Clip Values do przycinania skrajnych wartości i `series_outliers()` w Kusto do analizy szeregów czasowych.
- **Zachowaj rozsądek** – metody przygotowania danych powinny być dostosowane do kontekstu biznesowego. Współpracuj z ekspertami domenowymi, aby zrozumieć znaczenie cech i ewentualnych anomalii.

WARSTWOWY PROCES OCENY DANYCH

Profilowanie i analiza statystyk


Pierwszym etapem jest profilowanie danych i analiza statystyk, które pozwalają zrozumieć rozkład danych, brakujące wartości oraz wskaźnik duplikatów.

Walidacja reguł biznesowych


Kolejnym etapem jest weryfikacja zgodności z regułami biznesowymi, co pomaga wykryć nieprawidłowości wynikające z niezgodności z ustalonymi zasadami.

Ciągłe monitorowanie i wykrywanie anomalii

Ostatnia warstwa polega na stałym monitorowaniu jakości danych oraz automatycznym wykrywaniu nietypowych wzorców, by szybko reagować na problemy.



SKĄD DANE??



DWA ŹRÓDŁA

Dane otwarte

Generatory
danych

NAJLEPSZE ŹRÓDŁA DANYCH DLA AI

Źródło	Typ danych	Zastosowania	Link
Hugging Face	NLP, CV, Audio, Multimodal	Trenowanie modeli językowych, wizualnych, audio	https://huggingface.co/datasets
Kaggle	Różne (tekst, obrazy, liczby)	Projekty ML, AI, analizy danych	https://www.kaggle.com/datasets
Google Dataset Search	Różne (globalne źródła)	Wyszukiwanie danych dla NLP, CV, IoT, Big Data	https://datasetsearch.research.google.com
AWS Open Data	Big Data, obrazy, genomika	Analiza satelitarna, IoT, AI	https://registry.opendata.aws
Azure Open Datasets	Pogoda, finanse, transport	AI, ML w chmurze Azure	https://learn.microsoft.com/en-us/azure/open-datasets/
Common Crawl	Tekst z internetu	Trenowanie LLM, analiza języka	https://commoncrawl.org
LAION	Tekst + obrazy (multimodal)	Generatywne AI, trenowanie modeli wizualnych	https://laion.ai
OpenAI Datasets	NLP, tekst	Generacja tekstu, trenowanie modeli językowych	https://openai.com

NAJLEPSZE POLSKIE ŹRÓDŁA

Źródło	Typ danych	Zastosowania	Link
dane.gov.pl	Ogólne: statystyki, zdrowie, transport	Analizy Big Data, NLP, modele predykcyjne	dane.gov.pl
GUS – API	Statystyki gospodarcze, społeczne, środowiskowe	Analizy ekonomiczne, demograficzne, predykcja	api.stat.gov.pl
Bank Danych Lokalnych (BDL)	Wskaźniki regionalne (gmina/powiat)	Modele demograficzne, analizy regionalne	https://bdl.stat.gov.pl
NFZ – API	Dane o świadczeniach zdrowotnych	Analizy medyczne, prognozy zapotrzebowania	api.nfz.gov.pl
Geoportal / GUGiK	Dane przestrzenne, ortofotomapy, LIDAR	GIS, analizy przestrzenne, modele CV	https://geoportal.gov.pl
Biblioteka Narodowa	Rekordy bibliograficzne, ISBN	NLP, analizy tekstowe, sieci cytowań	https://data.bn.org.pl

FAKER – GENEROWANIE DANYCH TESTOWYCH W PYTHONIE

Tworzenie realistycznych
danych dla testów
programistycznych



CZYM JEST FAKER I JEGO ZASTOSOWANIA

Generowanie fałszywych danych

Faker umożliwia szybkie tworzenie realistycznych fałszywych danych do testów, baz danych i anonimizacji.

Wsparcie dla testów i lokalizacji

Biblioteka współpracuje z narzędziami testowymi i obsługuje różne języki oraz formaty regionalne.

Dostosowanie i rozszerzalność

Faker pozwala tworzyć własne providery, co umożliwia generowanie danych dopasowanych do projektu.

INSTALACJA I KONFIGURACJA

Prosta instalacja przez pip

Faker instaluje się łatwo przy pomocy polecenia `pip install Faker` w terminalu.

Wymagania wersji Pythona

Faker od wersji 5.0.0 wymaga Pythona 3.8 lub nowszego, nie wspiera już Pythona 2.

Import i użycie modułu

Po instalacji importujemy Faker i tworzymy instancję do generowania losowych danych.

Konfiguracja lokalizacji

Faker umożliwia ustawienie lokalizacji do generowania danych w różnych językach i formatach.



PODSTAWOWE GENEROWANIE DANYCH

Tworzenie instancji Faker

Podstawą jest stworzenie obiektu klasy Faker, który umożliwia generowanie losowych danych.

Generowanie różnych typów danych

Metody takie jak `name()`, `address()` czy `text()` generują różnorodne, losowe dane tekstowe i adresowe.

Wsparcie wielu kategorii danych

Faker obsługuje dane osobowe, finansowe, internetowe i lokalizacyjne, co zwiększa jego uniwersalność.

Rozszerzalność przez providerów

Możliwość dodawania własnych providerów pozwala na dostosowanie generatora do specyficznych potrzeb projektu.

OBSŁUGA LOKALIZACJI

Generowanie danych lokalnych

Faker umożliwia tworzenie danych zgodnych z lokalnymi językami i formatami, co zwiększa autentyczność testów.

Przykład użycia w Pythonie

Podanie kodu lokalizacji w instancji Faker pozwala generować dane takie jak polskie imiona i adresy.

Wsparcie wielu lokalizacji


Faker obsługuje wiele języków i pozwala na łączenie różnych lokalizacji w jednym projekcie.

Aktywny rozwój społeczności

Społeczność stale dodaje nowe lokalizacje, rozszerzając możliwości testowania międzynarodowego.



UNIKALNE WARTOŚCI I SEEDOWANIE



Generowanie unikalnych wartości

Faker pozwala tworzyć unikalne dane, np. unikalne nazwy użytkowników bez powtórzeń.



Seedowanie generatora

Seedowanie umożliwia powtarzalność wyników, ważną w testach automatycznych.



Zastosowanie w testach

Seedowanie pozwala na przewidywalność danych i powtarzalność testów.



GENEROWANIE DANYCH Z CLI

Generowanie danych z CLI

Faker umożliwia szybkie generowanie przykładowych danych bezpośrednio w wierszu poleceń, co przyspiesza tworzenie dokumentacji i testów.

Opcje i lokalizacja danych

Można określić liczbę powtórzeń, separator oraz lokalizację, co pozwala generować dane w różnych formatach i językach.

Wszechstronność narzędzia

Faker w trybie CLI zachowuje pełną funkcjonalność API, co czyni go narzędziem użytecznym dla programistów i testerów.

PODSUMOWANIE I ZALETY FAKER

Prostota i elastyczność

Faker oferuje łatwą obsługę oraz możliwość tworzenia własnych rozszerzeń dla specyficznych potrzeb.

Wsparcie wielu lokalizacji


Obsługa wielu lokalizacji umożliwia testowanie aplikacji w różnych wersjach językowych i kulturowych.

Integracja z narzędziami testowymi

Faker łatwo integruje się z Pytest i Factory Boy, ułatwiając tworzenie realistycznych testów.

Zaawansowane funkcje generowania

Funkcje takie jak seedowanie, generowanie unikalnych wartości i obsługa CLI zwiększają funkcjonalność Faker.



ĆWICZENIA PRAKTYCZNE

WPROWADZENIE DO ROLI DATA SCIENTIST

Kluczowe zadania data scientist

Eksploracja i analiza danych wspiera podejmowanie decyzji oraz tworzenie modeli uczenia maszynowego.

Proces pracy data scientist

Pozyskanie i przygotowanie danych, analiza wzorców, tworzenie raportów i modeli predykcyjnych.

Znaczenie języka Python

Python oferuje prostą składnię, bogaty ekosystem i szerokie wsparcie społeczności dla data scientistów.

Wartość zespołów data science

Organizacje inwestują w data science, aby optymalizować procesy i przewidywać trendy rynkowe.



ZALETY PYTHONA W ANALIZIE DANYCH

Intuicyjna składnia

Python cechuje się prostą i intuicyjną składnią, co ułatwia szybkie pisanie kodu nawet początkującym programistom.

Bogaty ekosystem bibliotek

Python oferuje szeroki wybór bibliotek wspierających różne etapy analizy danych i tworzenia modeli predykcyjnych.

Wszechstronność i open-source

Python jest darmowym, otwartym językiem, kompatybilnym z wieloma platformami i narzędziami, idealnym do wielu zastosowań.

Dostępność materiałów edukacyjnych

Ogromna liczba kursów i dokumentacji sprawia, że nauka Pythona jest łatwo dostępna dla każdego zainteresowanego.



BIBLIOTEKI DO ANALIZY I WIZUALIZACJI DANYCH

BIBLIOTEKA

ZASTOSOWANIE

NumPy

Obliczenia numeryczne, operacje na macierzach

Pandas/Polars

Manipulacja i analiza danych tabelarycznych

Matplotlib

Wizualizacja danych, wykresy

Scikit-learn

Algorytmy uczenia maszynowego

TensorFlow

Głębokie uczenie, sieci neuronowe

PyTorch

Głębokie uczenie, elastyczne modele

PRZYKŁADOWY SCENARIUSZ


- Zazwyczaj projekt analizy danych jest przeznaczony do ustanawiania szczegółowych informacji dotyczących konkretnego scenariusza lub testowania hipotezy.
- Załóżmy na przykład, że profesor uniwersytecki zbiera dane o swoich studentach, w tym liczbę wykładów, godziny spędzonych na nauce i ostatnią ocenę osiągniętą na koniec egzaminu. Profesor może przeanalizować dane, aby ustalić, czy istnieje relacja między ilością czasu poświęconego na naukę, którą podejmuje student, a ostateczną oceną, jaką osiągnął. Profesor może wykorzystać dane do przetestowania hipotezy, że tylko studenci, którzy uczą się przez minimum X godzin, mogą spodziewać się zaliczenia.
- Zbadamy i przeanalizujemy oceny dla fikcyjnej grupy uniwersyteckiej z punktu widzenia profesora. Użyjemy notesów Jupyter i kilku narzędzi i bibliotek języka Python, aby wyczyścić zestaw danych, zastosować techniki statystyczne, aby przetestować kilka hipotez dotyczących danych i zwizualizować dane w celu określenia relacji między zmiennymi.

EKSPLOROWANIE DANYCH ZA POMOCĄ BIBLIOTEK NUMPY I PANDAS

- Analitycy danych mogą używać różnych narzędzi i technik do eksplorowania, wizualizowania i manipulowania danymi. Jednym z najpopularniejszych sposobów, w jaki analitycy danych pracują z danymi, jest użycie języka Python i niektórych określonych pakietów do przetwarzania danych.
- **Co to jest biblioteka NumPy?**
- NumPy to biblioteka języka Python, która zapewnia funkcje porównywalne z narzędziami matematycznymi, takimi jak MATLAB i R. Chociaż biblioteka NumPy znacznie upraszcza środowisko użytkownika, oferuje również kompleksowe funkcje matematyczne.
- **Co to jest biblioteka Pandas?**
- Pandas to niezwykle popularna biblioteka języka Python do analizy danych i manipulowania nimi. Biblioteka Pandas jest jak aplikacja arkusza kalkulacyjnego dla języka Python, zapewniając łatwą w użyciu funkcję tabel danych.

EKSPLOROWANIE DANYCH W NOTESIE

- Notatniki to popularny sposób uruchamiania podstawowych skryptów za pomocą przeglądarki internetowej. Zazwyczaj te notesy są jedną stroną internetową podzieloną na sekcje tekstowe i sekcje kodu, które można uruchamiać indywidualnie.



The screenshot shows a Jupyter Notebook window with a dark theme. The title bar includes 'File', 'Edit', 'Selection', 'View', 'Go', 'Run', 'Terminal', and 'Help'. The notebook has two tabs: 'numpy-pandas.ipynb' (active) and 'grades.csv'. The active cell is a code cell with the following content:

```
data = [50,50,47,97,49,3,53,42,26,74,82,62,37,15,70,27,36,35,48,52,63,64]
print(data)
```

Below the code cell, the output is displayed:

```
[4]: ✓ 0.0s Open 'data' in Data Wrangler
[50, 50, 47, 97, 49, 3, 53, 42, 26, 74, 82, 62, 37, 15, 70, 27, 36, 35, 48, 52, 63, 64]
```

The notebook content includes the following text:

Exploring data arrays with NumPy

Let's start by looking at some simple data.

Suppose a college professor takes a sample of student grades from a class to analyze.

Run the code in the following cell by selecting the ► **Run** button to see the data.

The data has been loaded into a Python **list** structure, which is a good data type for general data manipulation which includes specific data types and functions for working with *Numbers* in Python.

Run the following cell to load the data into a NumPy **array**.

```
import numpy as np
```

TESTOWANIE HIPOTEZ

- Eksploracja i analiza danych jest zazwyczaj *procesem iteracyjnym* , w którym analityk danych pobiera próbkę danych i wykonuje następujące rodzaje zadań do analizowania i testowania hipotez:
 - **Czyszczenie danych** w celu obsługi błędów, brakujących wartości i innych problemów.
 - **Zastosuj techniki statystyczne, aby lepiej zrozumieć dane** i sposób, w jaki próbka może być oczekiwana do reprezentowania rzeczywistej populacji danych, co pozwala na losowe zmiany.
 - **Wizualizuj dane** w celu określenia relacji między zmiennymi, a w przypadku projektu uczenia maszynowego zidentyfikuj *funkcje* , które są potencjalnie predykcyjne *etykiety*.
 - **Zrewiduj hipotezę** i powtórz ten proces.

01 DATA INTRO

WIZUALIZOWANIE DANYCH

- Analitycy danych wizualizować dane, aby lepiej je zrozumieć. Mogą skanować nieprzetworzone dane, badać miary podsumowania, takie jak średnie lub grafować dane. Grafy to zaawansowany sposób wizualizowania danych, a analitycy danych często używają wykresów do szybkiego rozpoznawania umiarkowanie złożonych wzorców.
- Grafowanie jest wykonywane w celu zapewnienia szybkiej jakościowej oceny naszych danych, co może być przydatne do zrozumienia wyników, znalezienia wartości odstających, zbadania sposobu dystrybucji liczb itd.
- Chociaż czasami wiemy z wyprzedzeniem, jaki rodzaj grafu będzie najbardziej przydatny, czasami używamy grafów w eksploracyjny sposób. Aby zrozumieć możliwości wizualizacji danych, rozważ następujące dane: lokalizację (x,y) samochodu samojezdnego. W postaci pierwotnej danych trudno jest zobaczyć wszelkie rzeczywiste wzorce. Średnia lub średnia informuje nas, że ścieżka samochodu była wyśrodkowana wokół $x=0,2$ i $y=0,3$, a zakres liczb wydaje się wynosić od około -2 do 2.

02 VISUALISATION

BADANIE DANYCH RZECZYWISTYCH

- Dane przedstawione w materiale edukacyjnym są często niezwykle doskonałe, zaprojektowane tak, aby pokazać uczniom, jak znaleźć jasne relacje między zmiennymi. Dane "świata rzeczywistego" są nieco mniej proste.
- Ze względu na złożoność danych "rzeczywistych" musimy sprawdzić nieprzetworzone dane pod kątem problemów przed ich użyciem.
- W związku z tym najlepszym rozwiązaniem jest sprawdzenie pierwotnych danych i przetworzenie ich przed użyciem, co zmniejsza błędy lub problemy, zwykle usuwając błędne punkty danych lub modyfikując dane w bardziej użyteczny formularz.

RZECZYWISTE PROBLEMY Z DANYMI

- Rzeczywiste dane mogą zawierać wiele różnych problemów, które mogą mieć wpływ na użyteczność danych i naszą interpretację wyników.
- Ważne jest, aby pamiętać, że na większość rzeczywistych danych wpływa czynniki, które nie zostały zarejestrowane w tym czasie. Na przykład możemy mieć tabelę czasów toru wyścigowego obok rozmiarów silnika; ale różne inne czynniki, które nie zostały zapisane, takie jak pogoda, prawdopodobnie również odegrały rolę. W przypadku problemów często możemy zmniejszyć wpływ tych czynników, zwiększając rozmiar zestawu danych.
- W innych sytuacjach punkty danych, które są wyraźnie poza oczekiwanymi wartościami — znanymi również jako "*wartości odstające*" — czasami mogą być bezpiecznie usuwane z analiz, chociaż musimy zadbać o to, aby nie usuwać punktów danych, które zapewniają rzeczywiste szczegółowe informacje.

RZECZYWISTE PROBLEMY Z DANYMI

- Innym typowym problemem w rzeczywistych danych jest stronnicza odchylenie. Stronniczość odnosi się do tendencji do wybierania niektórych typów wartości częściej niż inne w sposób, który błędnie przedstawia podstawową populację lub "rzeczywisty świat". Stronniczy może być czasami identyfikowany przez eksplorowanie danych, mając na uwadze podstawową wiedzę na temat tego, skąd pochodzą dane.
- Rzeczywiste dane zawsze będą miały problemy, ale analitycy danych często mogą przezwyciężyć następujące problemy:
 - Sprawdzanie brakujących wartości i źle zarejestrowanych danych.
 - Rozważając usunięcie oczywistych wartości odstających.
 - Badanie, jakie rzeczywiste czynniki mogą mieć wpływ na ich analizę i określenie, czy ich rozmiar zestawu danych jest wystarczająco duży, aby zmniejszyć wpływ tych czynników.
 - Sprawdzanie stronniczych danych pierwotnych i rozważenie ich opcji naprawy stronniczych, jeśli zostanie znaleziona.

03 REALDATA

04 ZADANIE

06 ZADANIE

05 FAKER