

LIDER AI W TRANSFORMACJI CYFROWEJ

WPROWADZENIE DO ZARZĄDZANIA WDROŻENIAMI AI,
JAN GRZYBOWSKI, LISTOPAD 2025



O MNIE



- Background: Technology Consulting
- Specjalizacja: Zarządzanie Programami/Delivery
- Chief Delivery Office w firmie AI
- Aktualnie: CEO w software house



I. WPROWADZENIE DO KURSU

- Cel kursu
- Struktura zajęć
- Jak pracujemy?
 - 5 sesji x 1,5h z przerwami 15min
 - Przerwa obiadowa 30min – 14.00-14.30
 - Praca końcowa AI Canvas

PLAN ZAJĘĆ

- Sesja #1 - Kontekst rynkowy AI i dlaczego projekty się nie udają (wnioski dla liderów)
- Sesja #2 - Jak identyfikować dobre przypadki użycia AI?
- Sesja #3 - Jak liczyć ROI z AI (prosto)?
- Sesja #4 - Jak prowadzić projekty AI: lekki cykl życia
- Sesja #5 - Build vs Buy vs Partner + Zadanie końcowe (AI Canvas)

SESJA I

KONTEKST RYNKOWY AI I DLACZEGO PROJEKTY SIĘ NIE
UDAJĄ (WNIOSKI DLA LIDERÓW)



TRZECIA FALA AI

Skąd ten szum?


- Eksplozja GenAI; obniżenie bariery wejścia
- Presja biznesu (“zróbmy coś z AI”)
- Rozbieżność między oczekiwaniami a realnym zwrotem
- Pułapka FOMO i wdrażania na siłę (opracowania TOP4)

~70–80% projektów AI kończy się niepowodzeniem


Proof of Concept → Produkcja (20%)

The most commonly reported uses of generative AI tools are in marketing and sales, product and service development, and service operations.


Share of respondents reporting that their organization is regularly using generative AI in given function, %¹



Most regularly reported generative AI use cases within function, % of respondents



When is generative AI likely to transform your organization?



PROJEKT „AI” VS PROJEKT „IT”

IT	AI
Wynik znany	Wynik niepewny
Logika zaprogramowana	Logika wytrenowana
“Stabilne” wymagania	Wymagania ewoluują
Mała rola danych	Dane = sukces/porażka
Test = poprawność funkcjonalna	Test = jakość modelu
Wdrożenie = koniec	Wdrożenie = początek
Stabilne utrzymanie	Model drift/Concept drift
Typowy błąd: scope creep	Typowy błąd: Window Dressing



DYSKUSJA

- Jakie macie doświadczenia z AI “3 fali”?
- Najciekawsze porażki i zawiedzione oczekiwania?

DLACZEGO PROJEKTY SIĘ NIE UDAJĄ (TOP 5)

- Źle zdefiniowany problem (technologia szuka problemu).
- Brak danych / złej jakości dane.
- Brak właściciela biznesowego (projekty sieroty).
- Organizacja nieprzygotowana (brak procesu, governance).
- Problem zbyt trudny technologicznie lub obciążony zbyt dużą zmiennością.

AMAZON

Amazon – AI do rekrutacji (2018)

Model trenował na CV z poprzednich 10 lat — głównie mężczyzn — i zaczął automatycznie obniżać ranking kobietom

- Utrata reputacji, wstrzymanie projektu, kosztowna restrukturyzacja procesów HR i publiczne potwierdzenie, że nie można „ślepo” ufać modelom.
- **Dane treningowe odzwierciedlały uprzedzenia historyczne → model powielił bias.**
- Audyt danych, współpraca z ekspertami HR, limitowanie wpływu modelu na decyzję.

ZILLOW

Zillow – algorytm prognoz cen nieruchomości (Zillow Offers)

Algorytm przewidywał ceny domów, na podstawie czego Zillow hurtowo skupował nieruchomości. Gdy rynek stał się ekstremalnie zmienny po pandemii, model zaniżał lub zawyżał wartości, generując kolosalne straty.

- Strata ok. 500–800 mln USD, zamknięcie całej linii biznesowej, zwolnienia tysięcy pracowników.
- **Silny concept drift – rynek odjechał od historycznych wzorców.**
- Monitoring driftu, skalowanie krokowe, decision support zamiast automatyzacji decyzji finansowych

<https://insideainews.com/2021/12/13/the-500mm-debacle-at-zillow-offers-what-went-wrong-with-the-ai-models/>

IBM WATSON

System rekomendujący leczenie nowotworów działał na zestawach syntetycznych danych i nie radził sobie z prawdziwymi przypadkami, czasem sugerując błędne lub niebezpieczne terapie.

- Silny cios reputacyjny dla IBM, anulowane kontrakty szpitali, a projekt praktycznie zakończył życie komercyjne.
- **Zbyt mało realnych danych medycznych + zbyt duże obietnice marketingowe**
- Walidacja kliniczna, ograniczanie komunikacji marketingowej, etapowe wdrożenia na realnych danych pacjentów

<https://www.statnews.com/2018/07/25/ibm-watson-recommended-unsafe-incorrect-treatments/>



MICROSOFT TAY

Microsoft Tay – chatbot przejęty przez toksycznych użytkowników

Tay uczył się w czasie rzeczywistym na Twitterze i po kilku godzinach powtarzał rasistowskie, obraźliwe treści publikowane przez użytkowników. Microsoft musiał wyłączyć go po 16 godzinach.

- Wizerunkowa katastrofa, fala negatywnych artykułów, utrata zaufania do zdolności Microsoftu w bezpiecznym wdrażaniu AI.
- **Brak zabezpieczeń, brak filtrów treści, podatność na manipulację**
- Filtry toksyczności, mechanizmy moderacji, środowisko kontrolowane przed publicznym uruchomieniem, kill-switch.

<https://techcrunch.com/2016/03/25/microsoft-apologizes-for-hijacked-chatbot-tays-wildly-inappropriate-tweets>

HUMANE AI PIN

Urządzenie kosztujące 699 USD, zapowiadane jako „następny telefon”, ale okazało się, że funkcje nie spełniały oczekiwań, urządzenie zostało porzucone <1 rok po uruchomieniu.

- Utrata reputacji, eksternalizacja (sprzedaż aktywów do HP za 116 mln USD), klienci zamienili drogie gadżety na „papierowe ciężarki”.
- **Zbyt ambitne założenia, słaba jakość wykonania + niewłaściwy problem biznesowy (hardware do zastąpienia smartfona bez realnej przewagi).**
- Lekcja dla liderów: Upewnij się, że problem, który chcesz rozwiązać, naprawdę istnieje i że użytkownicy są gotowi zmienić nawyk.

the Humane AI Pin Failure: A \$700 Lesson in Product Strategy and Market Reality – 30 Lipca 2025

TESLA AUTOPILOT / FSD

Technologia wspomagająca prowadzenie samochodu była promowana jako bardzo zaawansowana, ale w praktyce dochodziło do wypadków i zarzutów wprowadzania klientów w błąd poprzez marketing „pełnej autonomii”.

- Utrata zaufania, koszty prawne i regulacyjne, obniżenie wartości akcji, potrzeba rewizji komunikacji marketingowej.
- **Niejasne oczekiwania, nadmierny hype, różnica między oszacowanymi możliwościami a rzeczywistością – model technologiczny nie nadążał za komunikacją.**
- Lekcja dla liderów: Komunikacja powinna odzwierciedlać rzeczywistą zdolność rozwiązania — nie sprzedawaj funkcji, które nie są gotowe.

QUIZ #1

- Najważniejsza różnica między AI a klasycznym IT?
- Jaki jest najczęstszy powód porażki projektów AI?
- Dlaczego dane są kluczowe w AI?
- Prawda/fałsz: Po wdrożeniu projekt AI jest zakończony.

MATERIAŁY

- *Spektakularne porażki AI*
- *RAND_RRA2680-1.pdf* — RAND (2024)
- *Enterprise Guide to AI ROI Measurement.pdf* (2024)
- *WDI24 Jan Grzybowski Presentation.pdf* (2024)
- HBR — *Why So Many AI Projects Fail* (2020)
- HBR — *Keep Your AI Projects on Track* (2023)
- MIT/Fortune — *95% of GenAI Pilots Fail to Deliver ROI* (2025)
- Deloitte — *State of Generative AI in the Enterprise* (2024)
- McKinsey — *The State of AI 2023* (2023)
- Economist — *How Businesses Are Actually Using GenAI* (2024)

SESJA 2

JAK IDENTYFIKOWAĆ DOBRE PRZYPADKI UŻYCIA AI (AI
OPPORTUNITY DISCOVERY)

PODSTAWOWE WZORCE AI

- Rozpoznawanie treści (obrazy, teksty, anomalie).
- Rozmowa / generacja (LLM, voiceboty).
- Predykcja (popyt, ryzyko, churn).
- Preskrypcja (co to oznacza?)
- Rekomendacje (co dalej zrobić).
- Personalizacja (lepsze dopasowanie treści).
- Automatyzacje inteligentne (agent AI).

CECHY DOBREGO PRZYPADKU AI

- Da się policzyć wynik.
- Proces jest powtarzalny i masowy.
- Dane istnieją lub są łatwo dostępne.
- Wartość biznesowa > koszt eksperymentu.
- Ryzyko prawne niskie lub oswojone.

GDZIE SZUKAĆ POMYSŁÓW

- Obsługa klienta → automatyzacja dialogu.
- HR → selekcja CV, churn.
- Finanse → anomalie, fraud.
- Marketing → segmentacja, generowanie treści.
- Operacje → prognozy, optymalizacja.

ANTY PRZYKŁADY

- Chatbot obsługujący reklamacje → chaos i eskalacje.
- AI automatycznie odrzucająca kandydatów → bias i pozwy.
- Automatyczne blokady finansowe → utrata klientów.
- Masowa generacja treści → PR-blunders, AI-slop.
- Prognozy bez walidacji → straty operacyjne.

AI OPPORTUNITY FILTER

- Czy to jest powtarzalne?
- Czy to boli biznes?
- Czy są dane?
- Czy da się zmierzyć efekt?
- Czy ryzyko (np. regulacyjne) jest akceptowalne?

Value Score:

- 1 = minimalna wartość,
- 5 = duży wpływ na (P&L).

Feasibility/Complexity Score:

- 1 = brak danych / wysokie ryzyko,
- 5 = dane gotowe + proces stabilny.

DYSKUSJA

- Gdzie w Waszej firmie są najbardziej powtarzalne decyzje?
- Który proces generuje najwięcej błędów/marnotrawstwa?
- Gdzie eksperymentujecie z AI?



QUIZ #2

- Wymień jeden wzorzec AI.
- Co jest najważniejszą cechą dobrego procesu dla AI?
- Czy każdy przypadek nadaje się do AI?
- Prawda/fałsz: AI najlepiej radzi sobie z procesami unikalnymi.

SESJA 3

W JAKI SPOSÓB SZACOWAĆ Z AI „PO LUDZKU”?



Z GODZIN NA ZŁOTÓWKI

- Oszczędność = liczba godzin $\times$ koszt godziny.
- Przychód = wzrost konwersji $\times$ wolumen $\times$ marża.
- Koszt uniknięty: błędy $\times$ koszt błędu $\times$ wolumen.

AI usprawnia proces $\rightarrow$ my zamieniamy to na wartość finansową.

Z GODZIN NA ZŁOTÓWKI

- Asystent LLM skraca obsługę zgłoszenia o 3 minuty, co przy 50 tys. zgłoszeń rocznie daje $2\,500 \text{ godzin oszczędności} \times 80 \text{ zł} = 200\,000 \text{ zł}$ rocznie.
- Jeśli AI podniesie konwersję na stronie z 2% do 2,4% przy 1 mln wizyt i średniej marży 20 zł, to daje dodatkowe ~80 000 zł miesięcznie.
- Model wykrywający błędy w fakturach ograniczył liczbę pomyłek o 300 miesięcznie, a każda kosztowała firmę średnio 50 zł — to 15 000 zł kosztu unikniętego.
- Jeśli AI skraca onboarding pracownika z 5 do 3 dni, to oznacza 2 dni szybszej produktywności, którą łatwo policzyć jako konkretne złotówki

STRUKTURA KOSZTÓW W PROJEKCIE AI

Praca ludzi	Analityk biznesowy; Eksperti domenowi; Data Engineer; Data Scientist; Product Owner AI; Developerzy; DevOps/MLOps
Dane	Czyszczenie danych; Etykietowanie; Anonimizacja; Konsolidacja danych; Zakup danych zewnętrznych
Technologia / Infrastruktura	Chmura (compute + storage); GPU; Narzędzia ETL; Platformy MLOps; Integracje
Licencje / API	API LLM; OCR/Computer Vision; Monitoring modeli; Narzędzia developerskie
Utrzymanie (operacyjne)	Monitoring jakości; Retraining; Aktualizacja danych; Audyty compliance
Zmiana organizacyjna	Szkolenia; Adaptacja procesów; Tworzenie governance; Onboarding użytkowników
Koszty ryzyka / ukryte	Halucynacje; Błędy operacyjne; Ryzyko prawne; Reputacja; Koszt błędnych decyzji

MIARY FINANSOWE

- **ROI** % – ile zyskujemy względem inwestycji.
- **Payback** – w którym miesiącu projekt się zwróci.
- **NPV / IRR** – używane w działach finansowych do porównywania projektów.
- Zawsze rób **3 scenariusze**: konserwatywny / bazowy / ambitny.

UPROSZCZONA ANALIZA ROI

- KPI, który chcemy poprawić
- Obecny baseline(czas / błędy / konwersja / itp.)
- Oczekiwana poprawa (wartość)
- Oszczędność roczna (PLN)
- Koszt projektu(jednorazowy + roczny)
- Payback= koszt / miesięczna oszczędność
- Scenariusze (Konserwatywny/Bazowy/Ambitny)

DYSKUSJA

- Co zrobilibyście z odzyskanymi 10 h/tydzień?
- Jaki zwrot jest akceptowalny w Waszej firmie?
- Jaki jest horyzont czasowy?

QUIZ #3

- Która miara mówi najszybciej „kiedy projekt się zwróci”?
- Które miary służą do porównywania projektów inwestycyjnych?
- Jakie scenariusze warto tworzyć?
- Dlaczego „czas” zamieniamy na PLN?



SESJA 4

CYKL ŻYCIA PROJEKTU AI (WEDŁUG PMI)

CYKL



TYPOWE ROLE W PROJEKTACH AI

-
- **1. Właściciel biznesowy (Business Owner)** - Osoba odpowiedzialna za cel biznesowy projektu, definiuje KPI, wartość i decyduje o kierunku prac.
 - **2. Product Owner / AI Product Lead** - Łączy świat biznesu i technologii; zarządza zakresem, priorytetami i tym, jak AI ma działać w procesie.
 - **3. Ekspert domenowy (Subject Matter Expert)** - Dostarcza wiedzy o procesach, danych, regułach i realiach operacyjnych — bez niego model nie ma sensu.
 - **4. Analityk biznesowy / Data Analyst** - Pomaga zrozumieć dane, procesy, tworzy KPI, opisuje wymagania i wspiera ocenę wartości.
 - **5. Data Engineer** Przygotowuje dane: pobiera, czyści, scala, buduje pipeline'y — dzięki niemu dane są „używalne” dla modelu.
 - **6. Data Scientist** Projektuje i trenuje modele AI/ML, testuje różne podejścia, ocenia jakość i poprawia wyniki.
 - **7. ML Engineer / AI Engineer** Wprowadza model do systemu, optymalizuje go i przygotowuje pod uruchomienie w środowisku produkcyjnym.
 - **8. MLOps / DevOps for AI** - Dbą o wdrożenie, monitorowanie i utrzymanie modelu

ETAP I: DEFINICJA PROBLEMU/BUSINESS UNDERSTANDING

ROLE	WYNIK	WAŻNE
• Właściciel biznesowy • Analityk biznesowy • Ekspert domenowy • Product Owner AI	• Jasno opisany problem • KPI i kryteria sukcesu • Zakres procesu i użytkowników • Hipoteza wartości (wstępny ROI)	• Problem musi być konkretny i policzalny • Nie zaczynamy od technologii — tylko od wartości • Niejasny cel, za szeroki zakres • Brak właściciela biznesu • Oczekiwania co do AI

ETAP II: DATA UNDERSTANDING

ROLE	WYNIK	WAŻNE
• Data Engineer • Data Scientist • Ekspert domenowy • Analityk danych	• Inwentaryzacja danych • Ocena jakości i dostępności • Zrozumienie ograniczeń i luk • Decyzja, czy dane są wystarczające • Przykładowy zestaw	• Dane nie istnieją lub są niekompletne • Dane nie odzwierciedlają rzeczywistości • Problemy z dostępem / RODO • Zbyt optymistyczne założenia co do jakości danych

ETAP III: DATA PREPARATION

ROLE	WYNIK	WAŻNE
• Data Engineer • Data Scientist • Specjaliści ETL • Ekspert domenowy (walidacja)	• Oczyszczone dane gotowe do modelowania • Znormalizowane, scalone i opisane zbiory danych • Etykiety/annotacje (jeśli wymagane)	• Przeciąganie fazy („data swamp”) • Błędy w etykietowaniu • Zbyt wolny dostęp do danych z systemów • Techniczne długi i chaos strukturalny

ETAP IV: MODEL DEVELOPMENT

ROLE	WYNIK	WAŻNE
• Data Scientist • ML Engineer • Ekspert domenowy • Product Owner AI	• Wstępny model / workflow AI • Wyniki testów jakości • Benchmark kilku podejść • Wybór najlepszego rozwiązania	• Overfitting / underfitting • Model nie spełnia KPI • „Magia AI” bez walidacji domenowej • Halucynacje w modelach generatywnych

ETAP V: MODEL EVALUATION

ROLE	WYNIK	WAŻNE
• Data Scientist • Ekspert domenowy • Product Owner AI • Analityk biznesowy	• Ocena jakości względem KPI • Ocena kosztów (API, infrastruktura) • Testy z użytkownikami • Decyzja GO / NO-GO na MVP	• Zbyt techniczna ocena jakości • Brak udziału biznesu • Ocenianie modelu tylko „na danych testowych” • Ignorowanie kosztów inference

ETAP VI: DEPLOYMENT

ROLE	WYNIK	WAŻNE
• ML Engineer • MLOps / DevOps • Developerzy (integracje) • Zespół procesowy / właściciel biznesu	• Model wdrożony do procesu • Stabilne środowisko produkcyjne • Monitoring jakości i kosztów • Procedury operacyjne + szkolenia użytkowników	• Brak adopcji użytkowników • Brak monitoringu (drift, halucynacje) • Niespójność danych między środowiskami • Niewystarczające testy obciążeniowe

ETAP VII: OPERATIONS

ROLE	WYNIK	WAŻNE
• MLOps • Data Scientist (retraining) • Product Owner AI • Właściciel procesu	• Ciągłe monitorowanie jakości • Wczesne wykrywanie driftu • Regularne aktualizacje danych i modeli • Raporty o wartości biznesowej	• Zanikanie jakości modelu (concept/data drift) • Rosnące koszty inference • Brak cyklicznych przeglądów ROI • „Zapomniane” modele działające bez nadzoru

AI DESIGN SPRINT

Szybki, 5-10dniowy proces, który pomaga **zdefiniować problem, zweryfikować dane i zaprojektować pierwszy prototyp AI** — zanim zainwestujemy w pełny projekt.

To sposób, by **obniżyć ryzyko**, sprawdzić **czy AI ma sens biznesowy**, i podjąć decyzję **GO / NO-GO**.

Dlaczego warto?

- Oszczędza 80% kosztów błędnych projektów AI
- Umożliwia testowanie pomysłów w kilka dni, a nie miesięcy
- Uczy zespół myśleć o AI przez pryzmat wartości biznesowej, nie technologii
- Idealny dla liderów, którzy chcą szybko ocenić potencjał AI w firmie

AI DESIGN SPRINT

Problem & KPI

- Zbieramy cele, ból biznesowy, KPI
- Ustalany, co jest „sukcesem”
- Identyfikujemy proces i użytkowników

Dane & wykonalność

- Audyt danych (źródła, jakość, dostępność)
- Ocena, czy projekt jest realny
- Decyzja: który use case ma największy potencjał

Koncepcja AI

- Wybór wzorca AI (LLM, klasyfikacja, predykcja, CV)
- Projektowanie przepływu użytkownika (human-in-the-loop)
- Szkic działania: input → AI → output

Mini-prototyp / eksperyment

- Budujemy szybki PoC:
- klasyfikator,
- prompt + LLM,
- prosty model predykcyjny
- Oceniamy jakość: top-5 wyników, halucynacje, koszty

Decyzja & roadmapa

- Czy projekt ma wartość > koszt?
- Co trzeba poprawić w danych?
- Jaki będzie plan MVP?
- Rekomendacja: GO / NO-GO

DYSKUSJA

- Której roli brakuje najbardziej w Waszych organizacjach?
- Gdzie najłatwiej o błędy ludzkie?

QUIZ 4

- Jakie są etapy projektu AI?
- Co to jest model drift?
- Dlaczego ekspert dziedzinowy jest kluczowy?
- Prawda/fałsz: projekt AI kończy się po wdrożeniu.

SESJA 5

SAMEMU CZY Z POMOCĄ?



BUY VS BUILD?

BUY

- Potrzebujesz **szybko**: copilotów, chatbotów, wyszukiwarki w dokumentach, analityki – i nie chcesz budować zespołu ML.
- Proces jest w miarę **standardowy** (support, marketing, HR, CRM).
- Firma jest na wczesnym etapie dojrzewanai AI, a Twoim celem jest „zdobyć pierwsze efekty i nauczyć organizację żyć z AI”.

BUILD

- Masz **unikalne dane** i procesy, które mogą dać realną przewagę.
- Jesteś gotów inwestować w zespół i **kompetencje AI jako core capability**, nie jako dodatek.
- Potrzebujesz **elastyczności i głębokiej integracji** z procesami i systemami dziedzinowymi
- Kwestie security/compliance

Wartość biznesowa ↓ / Wykonalność →	Niska wykonalność	Wysoka wykonalność
Wartość wysoka	BUILD (strategicznie) • Rozwiązanie może dać przewagę • Proces unikalny • Poprawić dane / procesy, potem budować • Ryzyko duże, ale potencjał wysoki	BUILD lub HYBRYDA • Dostrajanie modeli do danych • Elastyczne workflowy AI • Silna wartość + szybka realizacja
Wartość niska	NIE ROBIĆ / przełożyć • Słaby ROI • Brak danych • Proces niestabilny	BUY (kup) • Standardowy proces • Gotowe narzędzia pokrywają potrzeby • Szybkie wdrożenie, niski koszt

BUY – GOTOWE ROZWIĄZANIA - PROS

- **Szybszy time-to-value** - Gotowe narzędzia AI (chatboty, copiloty, analityka predykcyjna, platformy LLM) pozwalają „odpalić” pierwsze use case’y w tygodnie, a nie miesiące, co jest jednym z głównych argumentów za “buy”.
- **Niższy próg wejścia kompetencyjnego** -Platformy no-code / low-code i gotowe modele (np. w chmurach hyperscalerów) redukują potrzebę posiadania dużego zespołu data scientistów i ML engineerów in-house – to kluczowe w organizacjach na wczesnym etapie adopcji AI.
- **Sprawdzona technologia, mniejsze ryzyko R&D** - Dużi dostawcy inwestują setki milionów w rozwój modeli (foundation models, LLM), więc klient „kupi efekt skali” – w wielu przypadkach byłoby ekonomicznie absurdalne próbować odtworzyć to samemu.
- **Wbudowane bezpieczeństwo, zgodność i MLOps** - Produkty enterprise AI mają już warstwy: security, audyt, monitoring, role-based access, compliance (np. RODO, AI governance), co znacząco redukuje koszt i czas budowy własnego „otoczenia” wokół modelu.
- **Przewidywalne (z grubsza) koszty operacyjne** -Model subskrypcyjny (SaaS/API) pozwala łatwiej wkomponować koszty w OPEX – szczególnie atrakcyjne dla firm, które nie chcą dużych inwestycji CapEx w AI.

BUY – GOTOWE ROZWIĄZANIA - CONS

- **Vendor lock-in i zależność od roadmapy dostawcy** - Algorytmy, modele i feature'y są poza Twoją kontrolą; dostawca może zmienić ceny, limity, politykę danych, a roadmapa produktu może iść w inną stronę niż Twoje potrzeby. To jeden z głównych zarzutów wobec „buy” w raportach Gartnera i Forrester.
- **Ograniczona elastyczność** - Możesz konfigurować, ale nie „przełączyć” produktu – w złożonych lub bardzo specyficznych procesach (np. nietypowa logistyka, branże regulowane) gotowe rozwiązanie często nie pokrywa 100% wymagań albo wymaga kosztownych obejść.
- **Brak pełnej kontroli nad danymi i modelami** - Nawet jeśli dostawca deklaruje separację danych, często nie masz pełnego wglądu w to, jak model się uczy, jak działa wersjonowanie czy jakie dokładnie mechanizmy fairness i drift monitoring są używane.
- **Skalowanie może mocno podnieść koszty** - Początkowo tanie PoC, ale przy dużej skali (wiele użytkowników, ogromny wolumen zapytań do LLM, dużo predykcji) koszty API/SaaS potrafią eksplodować – Deloitte i BCG wskazują to jako jedną z top-3 przyczyn rozczarowania ROI z GenAI.
- **Trudności z budową unikalnej przewagi konkurencyjnej** - Jeśli wszyscy w branży kupują te same narzędzia i modele, przewaga rzadko wynika z samej technologii – musisz szukać jej w procesie, danych lub integracji, ale nie w samym produkcie.

BUILD – GOTOWE ROZWIĄZANIA

- PROS

- **Możliwość stworzenia realnej przewagi konkurencyjnej** - Własne modele (np. dostrojone LLM, custom ML na Twoich danych) plus dopasowany proces mogą być trudne do skopiowania; firmy z top-kwartyla „AI maturity” czerpią większość zysku właśnie z **customowych** rozwiązań na swoich danych.
- **Pełna elastyczność i kontrola** - Możesz zmieniać architekturę, modele, hyperparametry, pipeline’y danych, UI – w tempie dyktowanym przez biznes, a nie przez roadmapę vendorów. Kluczowe w środowiskach o częstych zmianach (dynamiczne rynki, nowe produkty, regulacje).
- **Lepsze dopasowanie do danych i procesów** - Można zoptymalizować model dokładnie pod Twoje dane (np. język branżowy, specyficzne dokumenty, specyficzne wzorce fraudów), co często daje **wyższą jakość niż generica SaaS**.
- **Pełna własność IP i mniejsza ekspozycja na rosnące licencje** - Koszty przesuwają się bardziej w stronę pracy zespołu i infrastruktury, ale nie płacisz % od skali licencji SaaS – McKinsey podkreśla, że przy dużej skali to bywa tańsze niż „wieczny” model subskrypcyjny.
- **Możliwość stworzenia wewnętrznej kompetencji AI** - Budując, rozwijasz zespół, know-how i przewagę organizacyjną – w wielu analizach (BCG, MIT) to ważniejszy asset niż pojedynczy model.

BUILD – GOTOWE ROZWIĄZANIA

- CONS

- **Wysokie koszty wejścia (people-heavy)** - Trzeba mieć (albo pozyskać) data engineerów, data scientistów, ML engineerów, MLOps, architektów – a to są najbardziej deficytowe i najdroższe kompetencje na rynku.
- **Większe ryzyko projektowe i technologiczne** - Nie ma gwarancji, że uda się osiągnąć zakładany poziom jakości modelu; raporty RAND i MIT wskazują, że bardzo duża część projektów ML kończy się w „PoC limbo” – prototypy nigdy nie trafiają do stabilnej produkcji.
- **Konieczność zbudowania i utrzymania całego „otoczenia”** - Monitoring, drift detection, retraining, data governance, security, compliance – trzeba to zbudować samemu lub skleić z wielu komponentów, co zwiększa złożoność i koszty utrzymania.
- **Wysokie ryzyko technologicznego długu** - Złe wybory architektoniczne, „egzotyczne” frameworki, brak standardów MLOps → po kilku latach projekt staje się trudny/nieemożliwy do rozwijania i trzeba robić duże refaktoryzacje albo re-platforming.
- **Dłuższy time-to-value** - Nawet przy dobrym zespole, zbudowanie od zera: data pipelines + modele + integracje + monitoring zabiera miesiące, a nie tygodnie – co jest przeciwieństwem tego, co wiele organizacji oczekuje po „modnym AI”.

DYSKUSJA

- W jaki sposób budujecie rozwiązania AI?
- Czy to są obszary budowania przewagi konkurencyjnej?



QUIZ 4

- Co decyduje o wyborze Build vs Buy?
- Najczęstszy błąd firm zaczynających AI?
- Kiedy nie warto inwestować w dedykowane rozwiązania?.

PROJEKT KOŃCOWY

Zdefiniuj w grupie najbardziej obiecujący case dla rozwiązania AI -

- Problem
- Użytkownicy
- Wartość biznesowa
- Wzorzec AI
- Dane
- Ryzyka
- ROI (prosty)

Data

Which data do you need?

Skills

Which skills do you need for development?

Value Proposition

What us the value added by your project?

Integration

How will the project be integrated?

Customers

Who are the end customers?

Output

Which key metric are you optimizing for?

Stakeholders

Who are the key stakeholders?

Cost

What costs will the project incur?

Revenue

How will the project generate revenue?

